Politécnico
Castelo Branco
Escola Superior
de Tecnologia

Machine learning aplicado à previsão desportiva
Projeto 1

Diogo Neves Oliveira
Nº 20230319

Orientador
Professora Doutora Ana Paula Neves Ferreira da Silva

Coorientador
Professor Doutor Arlindo Ferreira da Silva

Trabalho de Projeto apresentado à Escola Superior de Tecnologia do Instituto Politécnico de Castelo Branco para cumprimento dos requisitos necessários à obtenção do grau de Licenciado em Engenharia Informática, realizado sob a orientação científica da Professora Doutora Ana Paula Neves Ferreira da Silva e coorientação do Professor Doutor Arlindo Ferreira da Silva, do Instituto Politécnico de Castelo Branco.

Janeiro 2026

Composição do júri

Presidente do júri
Mestre, Paulo Alexandre Correia da Silva Neves
Professor Adjunto da Escola Superior de Tecnologia de Castelo Branco

Orientador
Doutora, Ana Paula Neves Ferreira da Silva
Professor Adjunto da Escola Superior de Tecnologia de Castelo Branco

Arguente
Doutor, Fernando Sérgio Rodrigues de Brito da Mota Barbosa
Professor Adjunto da Escola Superior de Tecnologia de Castelo Branco

Mestre, Paulo Alexandre Correia da Silva Neves
Professor Adjunto da Escola Superior de Tecnologia de Castelo Branco

Agradecimentos

Gostaria de começar por expressar o meu sincero agradecimento à minha orientadora, Professora Doutora Ana Silva, não só por ter aceitado o desafio de orientar este projeto, mas sobretudo pela disponibilidade, rigor e orientação constante. O seu apoio foi fundamental para manter o rumo certo e transformar as dificuldades técnicas em oportunidades de aprendizagem. Estendo o meu agradecimento ao meu coorientador, Professor Doutor Arlindo Silva, pelos conhecimentos transmitidos e pelo acompanhamento efetuado ao longo do desenvolvimento deste trabalho.

Aos meus colegas de curso, deixo um agradecimento especial pelo companheirismo, pela entreajuda nos momentos mais exigentes e pela partilha de conhecimentos que tornaram este percurso académico mais enriquecedor.

Aos meus pais, dedico a minha profunda gratidão pelo apoio incondicional, pela paciência durante os momentos de maior pressão e por me terem proporcionado todas as condições para concluir esta etapa. Sem o vosso incentivo, este percurso não teria sido possível.

Por fim, uma nota de apreço à minha gata, pela companhia silenciosa e leal durante as longas horas de programação e escrita deste relatório.

Resumo

Este projeto aborda o desafio da previsão de resultados desportivos na Primeira Liga Portuguesa de futebol, um problema caracterizado pela natureza estocástica do jogo e pelo desequilíbrio de classes, nomeadamente a dificuldade intrínseca em prever empates. O objetivo principal consistiu no desenvolvimento de um modelo de Machine Learning capaz de prever o desfecho dos jogos (Vitória da Casa, Empate, Vitória do Visitante) utilizando dados históricos das últimas duas décadas. A metodologia envolveu a recolha e fusão de dados de duas fontes principais, *football-data.co.uk* e *FBref*, permitindo a construção de um *dataset* robusto composto por estatísticas de jogo, métricas avançadas (como *Expected Goals* e *Progressive Passes*) e dados de mercado (*odds*). Foram implementadas e comparadas diversas abordagens, incluindo Regressão Logística e Árvores de Decisão, com destaque para o algoritmo *XGBoost*. O processo de desenvolvimento evidenciou que a simples maximização da exatidão global resultava num modelo incapaz de prever empates, enviesando as previsões sistematicamente para as equipas favoritas. Para mitigar este problema, adotou-se uma estratégia de ponderação de classes (*class weights*), aceitando uma redução na exatidão global em prol de um aumento significativo na capacidade de detetar empates (*Recall*). Os resultados demonstram que as variáveis estatísticas criadas possuem um poder preditivo relevante quando comparadas com as *odds* das casas de apostas e que o tratamento adequado do desequilíbrio dos dados é crítico para a aplicabilidade do modelo em cenários reais.

Palavras chave

Machine Learning, Futebol, Primeira Liga Portuguesa, XGBoost, Regressão Logística, Árvores de Decisão, Previsão Desportiva.

Abstract

This project addresses the challenge of predicting sports results in the Portuguese First League, a problem characterized by the stochastic nature of the game and class imbalance, notably the intrinsic difficulty in predicting draws. The main objective was to develop a Machine Learning model capable of predicting match outcomes (Home Win, Draw, Away Win) using historical data from the last two decades. The methodology involved collecting and merging data from two main sources, *football-data.co.uk* and *FBref*, allowing the construction of a robust dataset composed of match statistics, advanced metrics (such as Expected Goals and Progressive Passes), and market data (odds). Several approaches were implemented and compared, including Logistic Regression and Decision Trees, with a focus on the XGBoost algorithm. The development process showed that simply maximizing global accuracy resulted in a model incapable of predicting draws, systematically biasing predictions towards favorite teams. To mitigate this issue, a class weighting strategy was adopted, accepting a reduction in global accuracy in favor of a significant increase in the ability to detect draws (Recall). The results demonstrate that the engineered statistical features possess relevant predictive power when compared to bookmaker odds and that properly addressing data imbalance is critical for the model's applicability in real-world scenarios.

Keywords

Machine Learning, Football, Portuguese First League, XGBoost, Logistic Regression, Decision Tree, Sports Prediction.

Índice Geral

1. Introdução 1
1.1 Enquadramento e Motivação 1
1.2 Definição do Problema 1
1.3 Objetivos 2
1.4 Planeamento do Trabalho 3
1.5 Estrutura do Relatório 4
2. Enquadramento do Problema 5
2.1 Inteligência Artificial e Machine Learning 5
2.2 Aprendizagem Supervisionada para Problemas de Classificação 6
2.2.1 Classificação Multiclasse e Codificação da Variável Alvo 7
2.2.2 Estimativa de Probabilidade e Confiança 7
2.2.3 Definição de Espaço de Características e Integridade Temporal 7
2.2.4 Desequilíbrio de Classes 8
2.3 Algoritmos de Machine Learning a Explorar 8
2.3.1 Regressão Logística (Logistic Regression) 8
2.3.3 Árvores de Decisão (Decision Trees) 9
2.3.4 Random Forest 9
2.3.5 *XGBoost* (*eXtreme Gradient Boosting*) 10
2.4 Métricas de Avaliação e Estratégia de Validação 10
2.4.1 Seleção de Métricas em Cenários de Desequilíbrio de Classes 10
2.4.2 Análise de Matriz de Confusão (3x3) 11
2.4.3 Métricas de Desempenho: Exatidão, Precisão e Recall 11
2.4.4 A *F1-Score*: A Métrica de Referência para o Projeto 14
2.4.5 Expectativas por Algoritmo 15
2.4.6 Metodologia de Validação Temporal (Backtesting) 15
3. Trabalho Relacionado 16
3.1 Análise Comparativa de Algoritmos na Literatura 16
3.2 Análise Comparativa de Abordagens e Resultados Anteriores 17
3.3 Síntese e Decisões de Projeto 18
4. Arquitetura Tecnológica e Ferramentas 20
4.1 Linguagem de Programação: *Python* 20

4.2 Bibliotecas de Software 21
4.2.1 Recolha e Automação: *Selenium* 21
4.2.2 Processamento e Engenharia de Atributos: Pandas e NumPy 21
4.2.3 Modelação e Tratamento de Desequilíbrio: *Scikit-learn* e *Imbalanced-learn* 22
4.2.4 Motor de Inferência: XGBoost 22
4.2.5 Visualização de Dados: Matplotlib e Seaborn 23
4.3 Ambiente de Desenvolvimento 24
4.3.1 Prototipagem e Análise: *Jupyter Notebook* 24
4.3.2 Controlo de Versões e Documentação: GitHub 24
4.3.3 Gestão Bibliográfica: Zotero 25
5. Implementação e Análise Experimental 26
5.1 Arquitetura de Aquisição e Processamento de Dados (ETL) 26
5.1.1 Seleção das Fontes de Dados (FBRef e football-data.co.uk) 26
5.1.2 Limpeza, Resolução de Entidades e Integração Temporal 28
5.2 Análise Exploratória de Dados 30
5.2.1 Análise Univariada e Distribuição das Classes 30
5.2.2 Análise de Correlação e Identificação de Padrões 34
5.3 Engenharia de Atributos (*Feature Engineering*) 37
5.3.1 Tratamento de Variáveis Categóricas e Identificadores 38
5.3.2 Variáveis de Desempenho Histórico e Forma Recente 39
5.4 Metodologia Experimental 42
5.4.1 Estratégia de Partição: *Strict Temporal Holdout* 42
5.5 Discussão dos Resultados e Seleção do Modelo 44
5.5.1 Comparação de Arquiteturas: Linear vs. Ensemble 44
5.5.2 Análise da Importância das Variáveis (*Feature Importance*) 48
5.5.3 Seleção do Modelo Final 50
5.5.4 Conclusão da Seleção 51
6. Conclusões 52
6.1 Síntese do Trabalho Desenvolvido e Resultados Alcançados 52
6.3 Propostas de Trabalho Futuro 52
7. Fontes 54

Índice de Ilustrações/Figuras

Figura 1 Cronograma: Previsão da Primeira Liga portuguesa com *ML* 3
Figura 2 Histograma da distribuição das classes H/D/A..... 31
Figura 3 Distribuição da média de pontos históricos das equipas da casa 32
Figura 4 Dispersão dos Golos Esperados (xG) históricos por jogo 33
Figura 5 Distribuição das Odds da equipa da casa (Odd_Casa_Bet365) condicionada pelo resultado final 33
Figura 6 Matriz de Correlação (Performance, Forma, Odds) 34
Figura 7 Relação entre a média de passes progressivos das equipas em confronto 35
Figura 8 Impacto da forma recente (últimos 5 jogos) no resultado do jogo atual . 36
Figura 9 Distribuição das classes após codificações (dataset de treino) 38
Figura 10 Correlação entre Odds Médias e Métricas avançadas..... 42
Figura 11 Gráfico de Linhas comparando a evolução do Recall (Empates) vs. Accuracy Global ao longo das iterações do modelo..... 47
Figura 12 Top 10 Feature Importance do Modelo Random Forest..... 50

Índice de Tabelas

Tabela 1 Comparação de desempenho algorítmico na literatura revista 17
Tabela 2 Resumo do Ecossistema Tecnológico..... 23
Tabela 3 Análise comparativa técnica e funcional entre as fontes de dados 28
Tabela 4 Exemplo da estrutura após integração temporal (Contexto N-1)..... 29
Tabela 5 Quantificação do desequilíbrio de classes no conjunto de dados total.. 31
Tabela 6 Taxonomia das *Features Engineering* no Dataset Final..... 37
Tabela 7 Lógica de Cálculo da Janela Deslizante (FIFO - 5 Jogos)..... 40
Tabela 8 Distribuição Temporal e Quantitativa dos Conjuntos de Dados 43
Tabela 9 Desempenho dos Modelos de Referência (Sem Balanceamento) 44
Tabela 10 Comparação de Performance XGBoost (SMOTE/Weights) vs Random Forest 48
Tabela 11 Matriz de Confusão Simplificada do Modelo Final (Random Forest)... 51

Índice de Equações

Equação 1 *Esquema de Matriz de Confusão aplicada a um problema de classificação multiclasse* 11
Equação 2 Métrica de Exatidão..... 12
Equação 3 Métrica de Precisão..... 12
Equação 4 Métrica da Recall..... 13
Equação 5 Cálculo da *F1-Score*..... 14
Equação 6 Cálculo da F1-macro através da média aritmética das F1-scores de cada classe 14
Equação 7 Cálculo da *F1-Score Weighted* através da média das *F1-sco*res ponderada pelo suporte de cada classe..... 15

Lista de abreviaturas, siglas e acrónimos

ANN – *Artificial Neural Network* (Rede Neuronal Artificial)
API – *Application Programming Interface*
CNN – *Convolutional Neural Network* (Rede Neuronal Convolucional)
CSV – *Comma-Separated Values*
DOM – *Document Object Model*
EDA – *Exploratory Data Analysis* (Análise Exploratória de Dados)
EST – Escola Superior de Tecnologia
ETL – *Extract, Transform, Load*
FIFO – *First-In, First-Out*
GCA – *Goal-Creating Actions* (Ações de Criação de Golo)
HTML – *HyperText Markup Language*
HTTP – *HyperText Transfer Protocol*
IA – Inteligência Artificial
IPCB – Instituto Politécnico de Castelo Branco
LSTM – *Long Short-Term Memory*
ML – *Machine Learning*
NaN – *Not a Number*
OOT – *Out-of-Time*
RGPD – Regulamento Geral de Proteção de Dados
RNN – *Recurrent Neural Network* (Rede Neuronal Recorrente)
RPS – *Ranked Probability Score*
SCA – *Shot-Creating Actions* (Ações de Criação de Remate)
SMOTE – *Synthetic Minority Over-sampling Technique*
SVM – *Support Vector Machine*
WAF – *Web Application Firewall*
xG – *Expected Goals* (Golos Esperados)
XGBoost – *eXtreme Gradient Boosting*

1. Introdução

Este relatório apresenta o meu projeto final de curso: *Machine Learning* aplicado à previsão desportiva. Neste capítulo é feito uma apresentação geral do trabalho desenvolvido, apresentando o contexto e a motivação que levaram à escolha do tema, os objetivos específicos a atingir e, por fim, a estrutura detalhada dos restantes capítulos que compõem este relatório.

1.1 Enquadramento e Motivação

Atualmente, é impossível ver um jogo de futebol sem sermos bombardeados com estatísticas. A análise de dados deixou de ser uma curiosidade e passou a ser central na forma como os clubes operam. O futebol, em particular, estabeleceu-se como um domínio de grande interesse académico e comercial, movendo uma grande quantidade de dados que podem ser analisados para obter vantagens competitivas.

Em Portugal, o futebol é um fenómeno de grande impacto social e económico. A Primeira Liga portuguesa, sendo o principal escalão do futebol nacional, é uma competição que gera um enorme interesse, sendo acompanhada por milhões de adeptos. Esta popularidade torna um projeto como este, um desafio com relevância, tendo sempre em mente que é uma tarefa complexa, dada a natureza competitiva do campeonato e a imprevisibilidade de cada jogo.

Foi precisamente para explorar este potencial que decidi aplicar técnicas de *Machine Learning* à realidade específica da Primeira Liga portuguesa. Este projeto visa explorar essa oportunidade, aplicando técnicas de *Machine Learning* ao contexto específico da Primeira Liga portuguesa.

A motivação para a realização deste trabalho não é exclusivamente académica, para o autor, o futebol sempre foi uma grande paixão e acompanhada, recentemente, por um forte interesse na área de Ciência de Dados. Ter a possibilidade de juntar estas duas paixões foi a oportunidade ideal. Para além disso os resultados têm aplicabilidade prática direta em diversos setores, incluindo o jornalismo desportivo, plataformas de análise estatística, plataformas de apostas, e até mesmo para os próprios clubes de futebol na análise de desempenho e tomada de decisão estratégica.

1.2 Definição do Problema

Este projeto aborda o desafio da previsão de resultados desportivos, onde a incerteza é muito elevada. O objetivo prático consiste em desenvolver um sistema computacional capaz de estimar a classificação final da Primeira Liga portuguesa de Futebol, identificando o provável campeão, através da previsão individual de todos os jogos até ao fim da época de análise.

O futebol é um desporto complexo de prever, esta complexidade deve-se, em grande parte, à baixa frequência de golos e ao facto de nem sempre a equipa com melhor desempenho estatístico vencer a partida. Desta forma, o problema não se resume a uma simples previsão binária, mas está decomposto em dois desafios distintos:

1. **Classificação Multiclasse e Probabilística** - A base deste problema reside na previsão do desfecho de um jogo individual. Tecnicamente, isto obriga o modelo a escolher entre três opções (Vitória, Empate, Derrota), o que é muito mais difícil do que apenas prever 'sim ou não'. O modelo recebe dados como histórico das equipas e as odds, mas o objetivo, não se limita à previsão dos vencedores. É fundamental que o modelo calcule individualmente os três desfechos. Precisamos dessas percentagens para, mais tarde, alimentar as simulações que vão projetar a época inteira.
2. **Desequilíbrio de Classes (O Problema do Empate)** - A principal dificuldade técnica identificada é prever os empates. No futebol existe o fator "casa", o que faz com que as vitórias dos anfitriões sejam muito mais frequentes, enquanto o empate é o resultado mais raro e difícil de separar. O risco aqui é tentar impedir que o modelo maximize a taxa de acerto geral, ele pode simplesmente ignorar que o empate existe. O desafio é impedir que isso aconteça e forçar o algoritmo a aprender os padrões dos empates, mesmo que sejam a classe mais rara.

Em suma, o problema consiste na construção de um modelo preditivo que maximize a capacidade de generalização para jogos novos, superando previsões estatísticas básicas e lidando eficazmente com o ruído natural da Primeira Liga portuguesa.

1.3 Objetivos

O principal objetivo deste projeto é o desenvolvimento e avaliação de um modelo de *Machine Learning* capaz de prever o vencedor da Primeira Liga portuguesa, com base em dados históricos.

Para alcançar este objetivo geral, o projeto desenrola-se através de vários passos práticos. O trabalho começa pela recolha e tratamento de dados provenientes de duas fontes, permitindo contruir uma base de dados sólida, seguida de uma análise exploratória para detetar padrões e correlações relevantes. Com base nesse conhecimento, avança-se para a criação de variáveis preditivas (*feature engineering*), focadas essencialmente no desemprenho recente das equipas.

Na fase de modelação, o foco está na comparação de desempenho entre as diferentes abordagens com diferentes tipos de modelos como o *XGBoost*, *Random Forest* e até referências mais simples como a Regressão Logística. Para validar os resultados, recorre-se a métricas como o *F1-Score* e *Log-Loss*, que asseguram não só a precisão, mas também a fiabilidade das probabilidades calculadas.

1.4 Planeamento do Trabalho

O desenvolvimento deste projeto seguiu uma sequência lógica de etapas, que fomos organizando à medida que o trabalho avançava. Para visualizar este percurso e assegurar uma progressão consistente, foi elaborado um diagrama de Gantt (Figura 1), que sintetiza as fases principais do projeto, realizadas entre setembro de 2025 e janeiro de 2026.

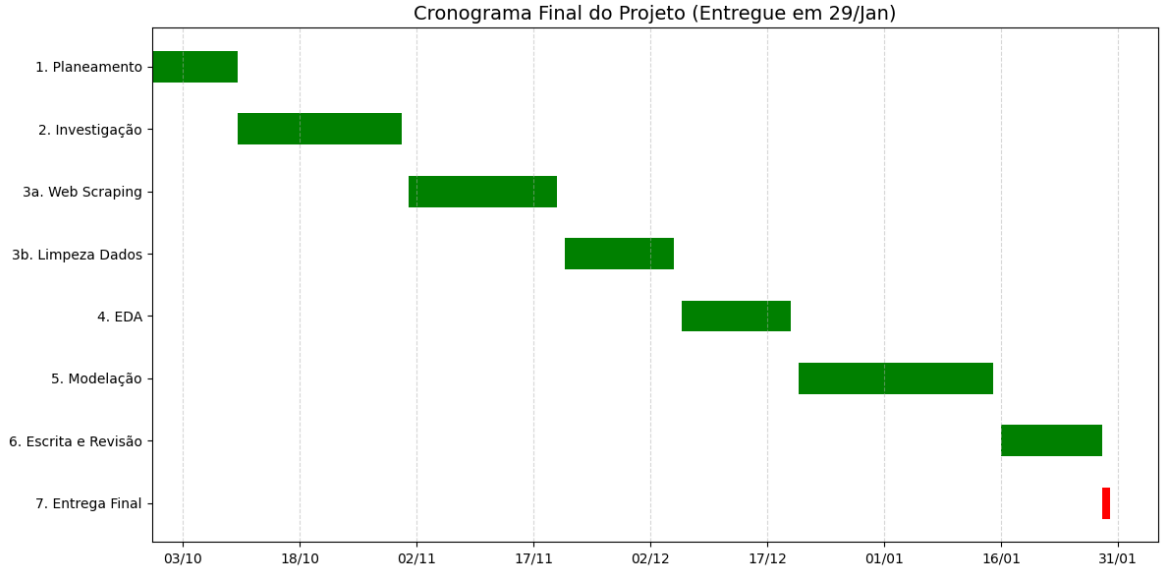

Figura 1 Cronograma: Previsão da Primeira Liga portuguesa com *ML*

A execução começou com uma fase inicial de pesquisa e estado da arte (setembro a outubro), onde o foco foi explorar a literatura científica sobre previsão de resultados desportivos com *Machine Learning*. O objetivo era identificar abordagens semelhantes e compreender o que já havia sido feito, para posicionar o projeto de forma relevante.

De seguida, passámos para a aquisição e processamento de dados (outubro a novembro), uma etapa muito prática. Aqui, foram desenvolvidos *scripts* para recolher dados automaticamente de fontes como o *FBRef*, usando a biblioteca *Selenium*, e depois concentrámo-nos na limpeza e integração de toda essa informação num conjunto de dados coerente.

Com os dados prontos, foi dado início à fase de análise exploratória e engenharia de atributos (novembro a dezembro). Este foi um período de descoberta, onde foram analisados os dados à procura de padrões e, ao mesmo tempo, foram criadas variáveis preditivas, como métricas de forma recente das equipas, e preparámos tudo para os modelos.

O centro do projeto foi a etapa de modelação e avaliação (dezembro a janeiro), onde foi feita a implementação, treino e otimização de vários algoritmos, como *Random Forest* e *XGBoost*. Foi um processo de testes e ajustes, avaliando o desempenho com métricas como *accuracy* e *F1-Score*.

Por fim, a última fase, foi dedicada a juntar todos os resultados e à redação deste relatório.

1.5 Estrutura do Relatório

O presente relatório encontra-se organizado em seis capítulos, que abordam de forma sistemática o problema de previsão desportiva.

- **Capítulo 1**: Serve de ponto de partida, onde é explicado o porquê de escolher este tema, defino os objetivos concretos a atingir e é apresentado o problema que o modelo terá de resolver.
- **Capítulo 2**: Aqui são definidas as "regras do jogo". São explicados os conceitos base de *Machine Learning* e justificadas a escolha das métricas de avaliação, fundamentais para entender se as previsões são boas ou não.
- **Capítulo 3**: Uma análise crítica do que já foi feito nesta área. É feita uma comparação de abordagens académicas e comerciais anteriores para perceber que métodos funcionam melhor e onde pode haver melhorias.
- **Capítulo 4**: Dedicado às ferramentas. Descrevo a *stack* tecnológica utilizada (*Python* e bibliotecas associadas) e explico como montei o ambiente para recolher e processar os dados.
- **Capítulo 5**: É o capítulo central do trabalho. É feito o processo de recolha de dados (*scraping*), a criação de novas variáveis (*feature engineering*) e todos os testes e afinações que fiz aos modelos até chegar aos resultados finais.
- **Capítulo 6**: Balanço final do projeto. Sintetizo o que foi alcançado, discute-se as limitações do modelo e deixo algumas sugestões para trabalhos futuros.

2. Enquadramento do Problema

Para ajudar à compreensão do problema que se pretende resolver neste projeto e à abordagem seguida, é importante definir os conceitos teóricos que o sustentam. Este capítulo aborda o enquadramento do trabalho na área da Inteligência Artificial, com especial foco em *Machine Learning* e no paradigma de Aprendizagem Supervisionada. Serão ainda detalhados os algoritmos e as métricas de avaliação essenciais para a construção e validação dos modelos preditivos.

2.1 Inteligência Artificial e Machine Learning

A realização de um sistema computacional capaz de prever o vencedor da Primeira Liga portuguesa de Futebol exige o enquadramento do projeto na área científica da Inteligência Artificial (IA), entendida não como uma abstração futurista, mas como uma disciplina de engenharia rigorosa focada na construção de agentes racionais. Embora o termo tenha sido cunhado formalmente em 1956 por John McCarthy, definindo a área como "a ciência e a engenharia de criar máquinas inteligentes" [1], a abordagem moderna e mais relevante para este projeto afasta-se da tentativa de replicar a mente humana (*pensar como humanos*) ou de passar no Teste de *Turing* (*agir como humanos*). Para fins de previsão desportiva, adota-se a definição operacional proposta por Stuart Russell e Peter Norvig na sua obra seminal *Artificial Intelligence: A Modern Approach* : a IA é o estudo de **agentes racionais** que agem de forma a alcançar o melhor resultado esperado, ou, em condições de incerteza, a melhor utilidade esperada, dadas as perceções disponíveis [2]. Neste contexto, o "agente" é o nosso modelo preditivo, o "ambiente" é a Primeira Liga portuguesa, e a "ação racional" é a classificação correta do resultado do jogo que maximiza a métrica de desempenho definida.

A operacionalização desta inteligência num sistema de *software* concretiza-se através de *Machine Learning*, que representa uma mudança de paradigma fundamental em relação à programação clássica. Enquanto a programação tradicional depende de regras explicitamente codificadas por humanos para processar dados, a ML inverte este fluxo, utilizando algoritmos para induzir regras a partir dos dados. Esta distinção foi pioneiramente observada por Arthur Samuel em 1959, que definiu o campo como a capacidade de dar aos computadores a habilidade de aprender sem serem explicitamente programados para cada eventualidade [3]. Contudo, para um projeto de engenharia informática, a definição formal proposta por Tom Mitchell em 1997 oferece uma estrutura metodológica mais precisa para a experimentação: diz-se que um programa aprende com a experiência ***E*** (neste caso, o histórico de estatísticas de jogos desde 2010), em relação a uma classe de tarefas ***T*** (a classificação do resultado em Vitória/Empate/Derrota) e uma medida de desempenho ***P*** (Exatidão, F1-Score ou *Log-Loss*), se o seu desempenho em ***T***, medido por ***P***, melhorar com a experiência ***E*** [4]. Esta formalização é crítica pois estabelece que o sucesso do projeto depende diretamente da qualidade e volume dos dados históricos (***E***) alimentados ao algoritmo.

É imperativo distinguir hierarquicamente os conceitos para justificar as escolhas tecnológicas do projeto. A *Machine Learning* é um subconjunto da IA, e o *Deep Learning* (Aprendizagem Profunda) é, por sua vez, um subconjunto especializado da ML que utiliza redes neuronais com múltiplas camadas para modelar abstrações complexas. Embora o *Deep Learning* tenha alcançado resultados notáveis em campos como a visão computacional, a revisão da literatura específica sobre previsão de resultados de futebol — nomeadamente o trabalho recente de Bunker et al. (2024) — sugere que, para dados tabulares estruturados com um número limitado de amostras (como é o caso de uma época desportiva com apenas 306 jogos), os modelos de "Shallow Learning", especificamente os algoritmos de **Gradient Boosting** (como o XGBoost), tendem a oferecer um desempenho superior ou equivalente às redes neuronais complexas, com maior eficiência computacional e interpretabilidade [5].

Assim, o problema central deste projeto configura-se como um desafio de **Aprendizagem Supervisionada** num ambiente estocástico e ruidoso. Ao contrário de jogos determinísticos como o Xadrez, o futebol contém uma elevada componente aleatória (ruído) que não pode ser totalmente modelada. O objetivo do agente racional não é, portanto, a certeza absoluta, mas a calibração precisa de probabilidades que superem a "sabedoria das multidões" implícita nas *odds* das casas de apostas. A aplicação de técnicas de ML neste domínio visa capturar padrões não-lineares e interações complexas entre centenas de variáveis (como *Expected Goals*, posse de bola e forma recente) que escapariam à análise estatística humana convencional, cumprindo assim o propósito último da Inteligência Artificial: extrair sinal preditivo a partir de dados complexos para apoiar a tomada de decisão em cenários de incerteza.

2.2 Aprendizagem Supervisionada para Problemas de Classificação

A solução baseia-se na Aprendizagem Supervisionada. O objetivo principal não é apenas analisar o passado, mas sim encontrar um padrão ou função que consiga generalizar bem, permitindo fazer previsões corretas em jogos novos que o modelo nunca viu

Em termos práticos, o problema resume-se a ensinar o computador com exemplos do passado. Matematicamente, isto traduz-se em encontrar uma função que mapeie os dados de entrada (estatísticas) no resultado final: $D = \{(x_i\,, y_i)\} i = 1$, onde:

- $x_i \in \Re^d$ representa o vetor de d características (*features*) de entrada (estatísticas das equipas e contexto do jogo);
- y_i corresponde à variável alvo (o resultado observado do jogo).

O processo de treino resume-se a encontrar uma função $f: X \rightarrow Y$ que consiga prever o resultado com o menor erro possível. No fundo trata-se de transformar os padrões identificados nas épocas anteriores em regras de decisão aplicáveis aos jogos futuros.

2.2.1 Classificação Multiclasse e Codificação da Variável Alvo

A tarefa foi modelada estritamente como um problema de classificação multiclasse, onde o espaço de saída Y é discreto e finito. Para viabilizar o processamento pelos algoritmos de otimização, efetuou-se a codificação numérica (*Label Encoding*) da variável alvo em três classes mutuamente exclusivas:

- **Classe 0 (H):** Vitória da equipa da casa (*Home Win*).
- **Classe 1 (D):** Empate (*Draw*).
- **Classe 2 (A):** Vitória da equipa visitante (*Away Win*).

Esta abordagem apresenta uma complexidade superior à simples classificação binária, sobretudo devido à introdução da classe "Empate". Conforme indicado na literatura especializada [6], o empate resulta frequentemente de um equilíbrio de forças ou ineficácia ofensiva, o que o torna estatisticamente mais difícil de separar das vitórias. Este fator constitui o principal desafio na maximização das métricas de desempenho do modelo.

2.2.2 Estimativa de Probabilidade e Confiança

Dado que o futebol é por natureza imprevisível, onde lesões, motivações ou até o tempo podem condicionar um resultado. O sistema evitar dar apenas uma classificação rígida. O objetivo da função $f(x)$ é estimar a probabilidade condicional de cada desfecho, tendo em conta as características do jogo:

$$P(Y = k \mid X = x), para\ k = \{0,1,2\}$$

Desta forma, o modelo fornece uma distribuição de probabilidades para as três classes possíveis (Vitória, Empate, Derrota), em vez de uma uma simples previsão do vencedor. Esta abordagem é crítica para a robustez da solução, pois permite quantificar o grau de confiança da previsão. Um jogo onde o modelo atribui 80% de probabilidade à vitória é muito diferente de um jogo onde a probabilidade é de apenas 40%, o que nos ajuda a distinguir previsões seguras de situações de alto risco.

2.2.3 Definição de Espaço de Características e Integridade Temporal

Na modelação de séries temporais, a definição do vetor de entrada x deve respeitar rigorosamente a ordem cronológica para evitar o fenómeno de *Data Leakage* (fuga de informação). Neste sistema, estabeleceu-se a restrição de que o vetor x_t, referente ao jogo no instante t, contém apenas dados disponíveis até ao instante $t - 1$.

O espaço de características (*features*) foi estruturado em duas categorias fundamentais:

- **Variáveis de Mercado:** *Odds* de abertura das casas de apostas, que representam a probabilidade implícita do mercado antes do início do jogo.
- **Métricas de Desempenho Histórico:** Estatísticas agregadas (ex: *Expected Goals*, posse de bola, eficiência defensiva).

Para operacionalizar esta estrutura, implementou-se uma lógica de desfasamento temporal (*time lag*) no pré-processamento. Este mecanismo assegura que as estatísticas utilizadas para prever um jogo da jornada N provêm exclusivamente dos dados consolidados das jornadas anteriores, simulando fielmente um cenário real de produção.

2.2.4 Desequilíbrio de Classes

A análise preliminar da variável alvo revelou um desequilíbrio estrutural na distribuição das classes, consistente com o fenómeno de "Vantagem Casa". Observa-se uma prevalência estatística significativa da Classe 0 (Vitória da Casa) em comparação com as Classes 1 e 2.

Este desequilíbrio apresenta um risco concreto para a modelação: os algoritmos de otimização, ao tentarem minimizar o erro global, tendem a convergir para uma solução que prevê sistematicamente a classe maioritária. Embora esta abordagem possa inflacionar artificialmente a métrica da Exatidão, resulta num modelo incapaz de detetar os eventos menos frequentes (Empates e Vitórias Visitantes), anulando a utilidade prática do sistema.

2.3 Algoritmos de Machine Learning a Explorar

A escolha dos algoritmos seguiu uma lógica de complexidade crescente. Começou-se por modelos simples para ter uma base de comparação e só depois avancei para métodos mais pesados, para perceber se o 'custo' computacional extra valia realmente a pena.

Esta abordagem comparativa procura responder a uma questão: verificar se o aumento da complexidade do modelo (e o consequente custo computacional) se traduz num ganho significativo na capacidade de generalização. O *pipeline* de treino integra quatro algoritmos distintos, ordenados por nível de complexidade estrutural: Regressão Logística, Árvores de Decisão, Florestas de Árvores de Decisão e *eXtreme Gradient Boosting*

2.3.1 Regressão Logística (Logistic Regression)

A Regressão Logística foi implementada como modelo de referência (*baseline*). A intenção não é que este seja o modelo com melhor performance absoluta, mas sim estabelecer um patamar mínimo de qualidade que permita validar se os ganhos trazidos pelos modelos mais complexos justificam o custo computacional.

Apesar de ser um algoritmo simples, esta abordagem é importante porque cumpre dois requisitos que se consideram fundamentais para o projeto. Primeiro, através da função Softmax, garante uma saída de probabilidades normalizada, o que é um pré-requisito para o nosso módulo de simulação. Segundo, funciona como uma ferramenta de diagnóstico: se esta *baseline* tiver um desempenho demasiado elevado, indicaria que a relação entre as estatísticas e o resultado é linear e simples, dispensando o uso de algoritmos mais pesados. Em termos de

implementação, foi obrigatório normalizar os dados previamente (*StandardScaler*), uma vez que a sensibilidade do algoritmo a diferentes escalas numéricas podia comprometer a convergência do treino

2.3.3 Árvores de Decisão (Decision Trees)

A introdução de Árvores de Decisão no *pipeline* surgiu da necessidade de superar as limitações do modelo anterior, que era demasiado linear. Como este algoritmo funciona através de regras condicionais, permite capturar interações muito mais complexas entre as variáveis (ex: a correlação entre posse de bola e probabilidade de vitória pode inverter-se dependendo do número de expulsões).

Este modelo ofereceu uma vantagem significativa na fase de depuração: a interpretabilidade (*White Box*). A possibilidade de visualizar a hierarquia de decisão permitiu validar a relevância das *features* criadas. No entanto, confirmámos nos testes preliminares que este algoritmo tem uma forte tendência para o *overfitting*, ou seja, acaba por memorizar o ruído dos dados de treino.

Para garantir a capacidade de generalização do modelo em dados de teste, foi mandatória a aplicação de técnicas de regularização durante o treino. Concretamente, impôs-se um limite rígido ao hiperparâmetro de profundidade máxima (*max_depth*). Ao fazê-lo, aceitámos perder alguma precisão no treino para ganhar estabilidade e fiabilidade na validação.

2.3.4 Random Forest

A implementação do *Random Forest* surge como a evolução natural para resolver a alta variância detetada nas árvores de decisão individuais, aplicando o método de *Bagging* (*Bootstrap Aggregating*). A literatura de referência em análise desportiva indica que modelos singulares são suscetíveis a *overfitting* em dados ruidosos. Com a agregação de múltiplos estimadores independentes conseguimos, estatisticamente, reduzir o erro de generalização e criar uma solução muito mais estável.

No contexto específico da Primeira Liga portuguesa, esta abordagem é essencial para lidar com *outliers* (jogos com resultados anómalos). Ao impor que cada árvore considere apenas um subconjunto aleatório de *features* em cada divisão, força-se a descorrelação entre os estimadores. Isto impede que variáveis dominantes distorçam a totalidade do modelo, permitindo a captação de sinais preditivos secundários frequentemente ignorados por modelos lineares.

Adicionalmente, este algoritmo desempenhou um papel funcional na etapa de Engenharia de Atributos (*Feature Engineering*). A métrica intrínseca de *Feature Importance* foi utilizada para quantificar o ganho de informação de cada variável, servindo de critério técnico para a seleção das estatísticas mais relevantes (como *xG*) e para a exclusão de variáveis ruidosas que não contribuíam para a performance preditiva.

2.3.5 *XGBoost* (*eXtreme Gradient Boosting*)

O algoritmo XGBoost foi selecionado como o modelo principal da arquitetura proposta, dado que, na literatura apresenta consistentemente os melhores resultados em dados estruturados. Diferenciando-se da abordagem de agregação paralela (*Bagging*) utilizada na *Random Forest*, este algoritmo implementa o paradigma de *Gradient Boosting*. Isto significa que constrói as árvores de forma sequencial, onde cada nova iteração tenta corrigir explicitamente os erros deixados pelo modelo anterior.

A adoção do XGBoost fundamentou-se em quatro características técnicas críticas para a viabilidade do sistema. Primeiro, a sua capacidade nativa para lidar com valores em falta (*Sparsity-aware*). Isto foi crucial para não termos de preencher artificialmente dados em registos históricos mais antigos, onde métricas modernas como os *Expected Goals* (xG) ainda não existiam. Segundo, oferece um controlo muito mais eficaz sobre o *overfitting* através de uma regularização híbrida (L1 e L2), superior ao simples limite de profundidade das árvores.

Além disso, configurámos a função objetivo como multi:softprob, o que garante que a saída seja um vetor de probabilidades normalizado para as três classes, um requisito obrigatório para alimentar o nosso motor de simulação. Por fim, a afinação cuidada dos hiperparâmetros, especialmente a taxa de aprendizagem (learning rate), foi o mecanismo principal para garantir que o modelo aprendia padrões gerais para a época de teste (2023/2024), em vez de apenas memorizar os dados de treino.

2.4 Métricas de Avaliação e Estratégia de Validação

Avaliar um modelo de futebol é traiçoeiro. Como a equipa da casa ganha quase metade das vezes, um modelo 'burro' pode ter uma boa nota de Exatidão sem saber nada de futebol. Por isso, a escolha das métricas foi feita para evitar essa armadilha.

Para evitar isso, o foco recai sobre o *F1-Score*, uma métrica baseada na Matriz de Confusão que exige um equilíbrio entre Precisão e *Recall*. Esta escolha garante que o modelo é penalizado se tentar ignorar os resultados mais difíceis, como os empates.

Além das métricas, também é abordada a estratégia de validação temporal, conhecida como *Walk-Forward Validation*. Ao contrário dos testes aleatórios tradicionais, esta abordagem respeita rigorosamente a ordem cronológica da época, impedindo que o sistema use informação do futuro para prever o passado (*data leakage*) e garantindo, assim, uma simulação fiel de um cenário real.

2.4.1 Seleção de Métricas em Cenários de Desequilíbrio de Classes

O problema de previsão do vencedor na Primeira Liga portuguesa resume-se a três hipóteses: Vitória da Casa (H), Empate (D) e Vitória do Visitante (A). A análise exploratória dos dados revelou um desequilíbrio estrutural nas classes, existe um forte *Home Advantage*, fazendo com que a vitória da casa seja o resultado mais comum. [7].

Este desequilíbrio torna a utilização da exatidão (*Accuracy*) perigosa e insuficiente. Um modelo base (*baseline*) que preveja sistematicamente "Vitória da Casa" atingiria uma Exatidão próxima dos 45-50%, sem demonstrar capacidade de aprendizagem . Para contornar esta tendência, a estratégia de avaliação implementada foca-se em métricas mais rigorosas calculadas através da biblioteca *scikit-learn* como a Matriz de Confusão, o *F1-Score* e o *Log Loss*.

O grande objetivo é impedir que o modelo tente maximizar a sua pontuação ignorando as classes minoritárias (os empates e as vitórias fora), pois num cenário de aplicação real, é frequentemente nestes resultados mais difíceis que reside o maior valor.

2.4.2 Análise de Matriz de Confusão (3x3)

Para diagnosticar exatamente onde é que o modelo está a falhar, utilizamos uma Matriz de Confusão de dimensão 3x3 (ver Equação 1). Esta ferramenta permite-nos ir além da simples taxa de acerto e analisar a distribuição dos erros.

$$C = \begin{pmatrix} C_{HH} & C_{HD} & C_{HA} \\ C_{DH} & C_{DD} & C_{DA} \\ C_{AH} & C_{AD} & C_{AA} \end{pmatrix}$$

Equação 1 *Esquema de Matriz de Confusão aplicada a um problema de classificação multiclasse*

A análise da matriz foca-se em dois vetores:

- **Diagonal Principal ($\boldsymbol{C_{HH}}$, C_{DD}, C_{AA}):** Representa os acertos (Verdadeiros Positivos). A magnitude de C_{DD} (acertos no Empate) é crítica, dado ser estatisticamente o resultado mais difícil de prever.
- **Erros Fora da Diagonal ($\boldsymbol{C_{ij}, i \neq j}$):** Permitem identificar enviesamentos. Por exemplo, uma elevada contagem em $\boldsymbol{C_{DH}}$ ou $\boldsymbol{C_{DA}}$ indica que o modelo confunde jogos equilibrados com vitórias claras, sugerindo sub-ajuste (no caso de modelos lineares como a Regressão Logística) ou deficiências na separação de classes.

Espera-se que algoritmos de *Gradient Boosting* (XGBoost) apresentem uma matriz mais "limpa", ou seja, com maior concentração de valores na diagonal em comparação com a Regressão Logística, devido à capacidade de criar fronteiras de decisão não-lineares e capturar interações complexas entre variáveis.

2.4.3 Métricas de Desempenho: Exatidão, Precisão e Recall

Partindo da decomposição feita pela Matriz de Confusão, é possível derivar um conjunto de métricas escalares. Estas métricas, frequentemente designadas por métricas de "*hard prediction*", avaliam a qualidade das classes finais atribuídas pelo modelo, ignorando, numa primeira fase, a incerteza probabilística associada a essas decisões. Para o projeto de previsão da Primeira Liga portuguesa, a tríade Exatidão, Precisão e *Recall* constitui o primeiro nível de validação formal dos algoritmos implementados.

- **Exatidão (Accuracy): A Ilusão da Competência**

A Exatidão é considerada, a métrica mais direta para avaliar um classificador. Uma vez que representa a proporção de previsões corretas face ao total de jogos observados. A formulação matemática usada neste projeto, bem como a problemática associada, encontram-se ilustradas na Equação 2. Em termos de implementação, recorremos à função *accuracy_score da biblioteca sklearn.metrics* [9].

$$\text{Accuracy} = \frac{\sum_{i \in \{H,D,A\}} C_{ii}}{\sum_{i \in \{H,D,A\}} \sum_{j \in \{H,D,A\}} C_{ij}} = \frac{TP_H + TP_D + TP_A}{N_{\text{total}}}$$

Equação 2 Métrica de Exatidão

Apesar da simplicidade de cálculo, a Exatidão é uma métrica que pode conduzir a más interpretações no contexto desportivo, particularmente devido ao desequilíbrio das classes. Na Primeira Liga portuguesa, a frequência de vitórias em casa ronda historicamente os 45-50% [8]. Um modelo ingénuo, que apostasse cegamente na "Vitória da Casa" em todos os jogos obteria automaticamente uma Exatidão próxima de 50%. Isto estabelece uma "linha de base" artificialmente alta.

Portanto, neste projeto, a Exatidão serve apenas como uma referência: qualquer modelo desenvolvido, seja Regressão Logística ou *XGBoost*, tem a obrigação de superar esta linha de base. Se não o fizer, o modelo não tem utilidade prática. Além disso, a Exatidão falha ao mascarar o desempenho nas classes minoritárias (como os Empates), que são frequentemente as que oferecem maior retorno em cenários de investimento.

- **Precisão (*Precision*): A Minimização do Risco**

A Precisão atua como uma métrica que visa a minimização de risco, uma vez que se foca na qualidade das previsões positivas. Para uma classe específica, como a Vitória do Visitante, esta métrica responde a uma pergunta: " De todas as vezes que o modelo garantiu que o visitante ia ganhar, quantas vezes é que isso aconteceu realmente?". A fórmula de cálculo, que relaciona os verdadeiros positivos com o total de avisos dados pelo modelo, encontra-se detalhada na Equação 3.

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}$$

Equação 3 Métrica de Precisão

Num cenário aplicado a apostas desportivas, a Precisão é uma métrica de segurança e minimização de risco, ou seja, Um Falso Positivo onde prevemos uma vitória que não se concretiza tem um custo direto elevado: a perda do valor apostado. Por isso é encarada como um indicador de segurança onde um modelo

com alta precisão é ideal para uma estratégia conservadora, pois sugere que quando o sistema decide "arriscar" uma previsão, a probabilidade de sucesso é muito elevada.

Na análise técnica feita através do *classification_report* do *scikit-learn*, é comum observar que modelos como a Árvore de Decisão apresentam uma precisão mais baixa do que modelos de ensemble como o Random Forest ou XGBoost. Isto acontece porque a árvore tende a decorar o ruído (*overfitting*) gerando mais Falsos Positivos no teste. A Random Forest, ao agregar múltiplas árvores (*Bagging*), reduz a variância e tende a filtrar esses falsos positivos, aumentando a Precisão [10].

- **Recall (Sensibilidade): A Captura de Oportunidades**

A Recall (ou Sensibilidade) mede a capacidade do sistema para capturar oportunidades. A pergunta aqui inverte-se: para uma determinada classe, como o Empate, queremos saber: "De todos os jogos que *realmente* terminaram empatados, quantos é que o modelo conseguiu identificar?". A formulação matemática encontra-se na Equação 4.

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}$$

Equação 4 Métrica da Recall

No contexto do projeto, a Recall é fundamental para avaliar se o modelo não está a "ignorar" classes difíceis. No futebol, a classe "Empate" é a que sofre mais frequentemente de baixa Recall. Muitos modelos, para maximizar a Exatidão global, tendem a prever muito poucos empates, resultando numa Recall próxima de zero para esta classe. Isto significa que o modelo está a perder a grande maioria das oportunidades de prever um empate. Num contexto de *scouting*, uma Recall baixa na vitória visitante significaria falhar na identificação de equipas que estão a ter performances surpreendentes fora de casa.

Neste trabalho tivemos que, lidar com o clássico compromisso (*trade-off*) entre estas duas métricas. Se tentarmos aumentar a Recall da classe "Empate" (tornando o modelo mais sensível a sinais de equilíbrio), é provável que a Precisão diminua, pois, o modelo começará a classificar mais jogos como empates, aumentando os Falsos Positivos. De uma forma geral, modelos probabilísticos como a Regressão Logística permitem ajustar este equilíbrio alterando o limiar de decisão (*threshold*). Contudo modelos baseados em regras rígidas como a Árvore de Decisão têm menos flexibilidade neste aspeto sem serem usadas técnicas de pós-processamento. Fazer uma análise conjunta de Precisão e Recall é, portanto, essencial para compreender o perfil de risco/retorno de cada algoritmo estudado [11].

2.4.4 A *F1-Score*: A Métrica de Referência para o Projeto

Tal como referido na secção anterior, existe um compromisso difícil entre a Precisão e a *Recall* e o desequilíbrio de classes no *dataset* da Primeira Liga portuguesa, torna este compromisso ainda mais complicado. A *F1-Score,* por sua vez, é uma métrica importante e talvez a mais adequada para a validação comparativa dos modelos neste projeto. Trata-se da média harmónica entre a Precisão e a Recall, proporcionando uma medida única que penaliza modelos que favorecem desproporcionalmente uma das métricas em detrimento da outra. A Equação 5 apresenta a fórmula matemática para esta medida.

$$F1_k = 2 \cdot \frac{\text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}$$

Equação 5 Cálculo da *F1-Score*

A escolha da média harmónica, em vez da média aritmética, é crucial. A média harmónica tende sempre para o menor dos dois valores. Por exemplo, se um modelo tiver uma Precisão de 100% na classe "Empate" (previu 1 empate e acertou) mas uma Recall de apenas 1% (existiam 100 empates e falhou 99), a média aritmética seria 50.5%, sugerindo um desempenho "médio". A *F1-Score*, contudo, seria aproximadamente 2%, refletindo corretamente a inutilidade prática de um modelo que falha em detetar 99% dos casos. É esta honestidade brutal que torna a *F1-Score* essencial para avaliar classes difíceis e minoritárias.

No contexto multiclasse, o *scikit-learn* permite agregar estas pontuações de várias formas. Para este projeto, focámo-nos em duas agregações fundamentais:

- ***F1-Score* Macro**

$$F1_{\text{macro}} = \frac{F1_H + F1_D + F1_A}{3}$$

Equação 6 Cálculo da F1-macro através da média aritmética das F1-scores de cada classe

Para a agregação dos resultados, recorremos a duas abordagens distintas. Primeiro, temos a *F1-Score* Macro, que calcula a média aritmética simples das três classes, conforme ilustrado na Equação 6. Esta métrica é democrática e implacável: atribui exatamente o mesmo peso a um empate e a uma vitória da casa, independentemente da frequência com que ocorrem.

É, por isso, a nossa métrica mais rigorosa para avaliar a competência "científica" do modelo. Se o algoritmo decidir ignorar os empates (porque são difíceis), a *F1-Score* dessa classe será zero e puxará a média Macro drasticamente para baixo, mesmo que o modelo seja ótimo a prever vitórias caseiras. É este o critério principal que usamos para decidir se vale a pena usar modelos complexos como o *XGBoost*.

- **F1-Score Weighted**

$$F1_{\text{weighted}} = \frac{N_H \cdot F1_H + N_D \cdot F1_D + N_A \cdot F1_A}{N_{\text{total}}}$$

Equação 7 Cálculo da *F1-Score Weighted* através da média das *F1-scores* ponderada pelo suporte de cada classe

Por outro lado, calculamos o F1-Score Weighted (Ver Figura 7), que pondera a média pelo número real de ocorrências (o suporte). Esta métrica tende a apresentar valores mais altos, pois dá mais peso à classe maioritária (Vitória da Casa), refletindo o desempenho esperado num cenário de volume real. O grande valor destas duas métricas está na sua comparação: se o F1-Weighted for muito superior ao F1-Macro, isso funciona como um alerta de diagnóstico, indicando que o modelo está enviesado e a sacrificar as classes mais raras para maximizar o acerto nas mais comuns [12].

2.4.5 Expectativas por Algoritmo

A análise comparativa parte de expectativas concretas para cada modelo, baseadas na forma como funcionam teoricamente:

1. **Regressão Logística:** Serve como a referência base (*baseline*). O foco está na análise dos coeficientes e na *Log Loss* para perceber até que ponto o problema pode ser resolvido de forma linear.
2. **Árvore de Decisão:** O foco principal é vigiar o *overfitting*. Monitoriza-se a discrepância entre métricas de treino e teste para validar a eficácia da poda (*pruning*).
3. **Random Forest:** Espera-se que corrija a instabilidade da árvore simples e um aumento da Precisão e uma redução de variância através do método de *Bagging* [10].
4. **XGBoost:** É a principal aposta para maximizar a *F1-Macro*. É esperado que através da otimização da função de perda e do ajuste de hiperparâmetros para lidar com o desequilíbrio (ex: *scale_pos_weight*) o tornem superior aos restantes.

2.4.6 Metodologia de Validação Temporal (Backtesting)

Tendo em conta que os dados desportivos seguem uma ordem cronológica obrigatória, foi descartada a tradicional validação cruzada aleatória (*K-Fold*) para evitar *data leakage* (uso de informação futura para prever o passado).

Em alternativa, implementou-se uma estratégia de Walk-Forward Validation (ou *Backtesting*). Na prática, definiu-se uma data de corte cronológica (ex: início da época 2023/24). Os modelos são treinados estritamente com dados anteriores a essa data e avaliados no conjunto posterior. Esta abordagem é fundamental porque simula o ambiente de produção real, garantindo que as métricas reportadas refletem a capacidade do modelo em lidar com a evolução temporal da forma das equipas e novos padrões táticos.

3. Trabalho Relacionado

Antes de avançar para o código, foi preciso perceber o estado da arte. O objetivo desta pesquisa não foi apenas académico, queria descobrir porque é que, no futebol, modelos teoricamente mais avançados como *Deep Learning* muitas vezes perdem para algoritmos mais simples.

A investigação foi estruturada em duas dimensões. Por um lado, a análise académica comparou o desempenho de modelos estatísticos clássicos (como a distribuição de Poisson) com algoritmos de *Machine Learning* modernos, incluindo *Random Forest*, *XGBoost* e Redes Neuronais. Por outro, uma análise prática de repositórios *open-source* e soluções comerciais, o que permitiu identificar os padrões de arquitetura mais usados em ambientes de produção.

Esta revisão da literatura permitiu chegar a duas conclusões técnicas fundamentais para o projeto. Primeiramente, confirmou-se a consistência do desempenho superior de modelos de *Gradient Boosting* em dados tabulares de futebol, frequentemente superando abordagens baseadas em redes neuronais complexas. Em segundo lugar, verificou-se que o fator determinante para a precisão do modelo não é apenas a escolha do algoritmo, mas sim a robustez da engenharia de atributos (*feature engineering*), nomeadamente através da incorporação de métricas dinâmicas de força relativa, como o sistema de *rating* Elo.

3.1 Análise Comparativa de Algoritmos na Literatura

A pesquisa da literatura científica permitiu traçar uma linha evolutiva clara: as abordagens estatísticas tradicionais estão a dar lugar a algoritmos de *Machine Learning*. Com base na literatura, identificámos quatro categorias principais que ajudaram a fundamentar as escolhas tecnológicas deste projeto:

1. **Modelos Estatísticos (*Baselines*)** - Métodos clássicos, como a distribuição de Poisson, continuam a ser relevantes [13]. Embora simples, são essenciais para a criação de sistemas de *rating* dinâmicos, que permitem a atualização da força relativa das equipas após cada jornada [2], [3], e servem para estabelecer o patamar mínimo de qualidade que qualquer modelo novo deve superar.
2. **Algoritmos Clássicos de Machine Learning** - Algoritmos como o *Random Forest* ou SVM são muito elogiados pela sua interpretabilidade e permitem perceber facilmente quais são as variáveis mais importantes. Funcionam bem em *datasets* pequenos, mas a literatura aponta-lhes limitações na captura de padrões complexos quando comparados com métodos de *boosting* [14], [15].
3. **Gradient Boosting em Dados Tabulares** – Existe um consenso prático de que algoritmos *Gradient Boosting* como o *XGBoost*, *LightGBM* e *CatBoost* representam o estado da arte para a previsão de resultados de futebol baseada em estatísticas estruturadas [16]. A sua superioridade deve-se à capacidade de modelar interações não-lineares e aos mecanismos de

prevenção de *overfitting*, motivos pelos quais foi eleito como o motor principal do nosso sistema [16].

4. **Limitações do *Deep Learning*** - Embora as Redes Neuronais sejam eficazes na extração de padrões temporais, a sua aplicação em dados tabulares de futebol apresenta resultados mistos [15]. O problema é a escassez de dados: uma época tem menos de 400 jogos, o que é insuficiente para treinar arquiteturas profundas. Os estudos indicam que, neste contexto, o *Deep Learning* raramente supera o *Gradient Boosting*, exigindo um esforço computacional que não compensa o ganho marginal de precisão [5], [15].

Tabela 1 Comparação de desempenho algorítmico na literatura revista

Categoria do Algoritmo	Algoritmo Específico	Características Chave Utilizadas	Métrica e Desempenho Reportado	Pontos Fortes/Fracos Notados
Probabilísticos	Dist. Poisson	Golos marcados/sofridos, vantagem de jogar em casa [13], [15], [17]	*Baseline* de referência	Bom para modelar contagens de golos, mas menos preciso que ML [13], [15], [17]
Regressão	Reg. Logística Multinomial	Estatísticas de jogos (remates, faltas, cartões) [18]	Precisão: 59.55% [18]	Simples, boa sensibilidade para vitórias em casa, mas limitado em relações não lineares [18]
Ensemble	*Random Forest*, SVM	Atributos de jogo e de jogadores [19]	Retorno econômico por aposta: 1.58% [19]	Abordagem robusta que combina múltiplos modelos; Boa performance consistente
Gradient Boosting	*CatBoost*, *XGBoost*	Ratings de equipas, estatísticas de jogo [16], [19]	RPS: 0.1989 Precisão: 53.61%-56% [16], [19]	Melhor desempenho em dados tabulares, superando DL; Dificuldade em prever empates [16], [19]
Deep Learning	*LSTM*, *CNN*	Sequências de desempenho, dados tabulares como imagens [5], [20]	Precisão: até 98.63% (dados proprietários) [5], [20]	Captura de dependências temporais; Não supera *Gradient Boosting* em dados públicos [5], [20]

3.2 Análise Comparativa de Abordagens e Resultados Anteriores

A comparação entre as diversas abordagens identificadas na literatura não se limitou à exatidão final (*accuracy*), avaliando também a robustez, o custo computacional e a capacidade de generalização dos modelos. A análise permitiu isolar padrões de desempenho e desafios técnicos recorrentes.

O Gradient Boosting vence Deep Learning**:** Apesar da popularidade das Redes Neuronais, para dados tabulares de futebol elas não compensam [16]. Estudos recentes demonstram que arquiteturas como CNN e LSTM não superam consistentemente as árvores de decisão quando limitadas aos *datasets* públicos disponíveis [5]. O *Gradient Boosting* continua a ser a abordagem mais eficiente pela

sua capacidade de lidar com não-linearidades sem precisar de volumes massivos de dados [16].

A Importância da Engenharia de Atributos (*Feature Engineering*) revela-se de extrema importância. Verifica-se que a qualidade dos dados de entrada (*Feature Engineering*) é mais determinante do que a complexidade do algoritmo escolhido. Os modelos com melhor desempenho na literatura são aqueles que integram métricas de força relativa, como sistemas de *rating Elo* e médias móveis de estatísticas de jogo (remates, cantos) que ajudam a extrair sinal no meio do ruído [15].

O Desequilíbrio de Classes e a Previsão de Empates identificou-se uma limitação transversal à maioria dos estudos: quase todos os modelos falham na previsão de empates. Este problema decorre do desequilíbrio de classes os empates são estatisticamente menos frequentes e da menor separabilidade linear deste resultado [15]. Consequentemente, métricas globais como a *accuracy* podem induzir em erro, optando-se neste projeto pela avaliação através do *F1-Score* por classe e do *Ranked Probability Score* (RPS) para garantir uma validação rigorosa [16].

A Reprodutibilidade e Validação Metodológica são muito importantes. A comparação entre a literatura científica e soluções comerciais evidenciou diferenças ao nível da validação técnica. Enquanto as fontes académicas detalham metodologias que garantem a reprodutibilidade como a prevenção de *data leakage* através de validação temporal estrita [21], as soluções comerciais carecem frequentemente de especificações verificáveis [22]. O desenvolvimento deste projeto segue, portanto, as metodologias abertas validadas pela comunidade científica, priorizando a transparência do código em detrimento de abordagens proprietárias ("caixas negras").

3.3 Síntese e Decisões de Projeto

A análise do estado da arte ajudou a definir a arquitetura do sistema. Confirmou-se a ideia de que, para dados de futebol em formato tabular, aumentar a complexidade com redes neuronais não garante necessariamente mais precisão. Pelo contrário, os modelos de *ensemble* baseados em árvores de decisão mostram um equilíbrio muito superior entre a capacidade de previsão e a eficiência computacional. Com base na revisão efetuada, estabeleceram-se as seguintes decisões técnicas para o desenvolvimento do projeto:

Seleção Algorítmica: Foi escolhido o *XGBoost* como motor principal do sistema, dada a sua capacidade comprovada para lidar com não-linearidades e resistência a *outliers*. Para efeitos de comparação, será implementada uma Regressão Logística como modelo de referência (*baseline*), permitindo medir o ganho real trazido pela complexidade do *boosting*.

Estratégia de Engenharia de Atributos: Identificou-se que a qualidade dos dados é um fator crítico de diferenciação. A estratégia de dados passa por uma fusão de fontes diferentes: dados históricos de resultados e *odds* (via *football-data.co.uk*) integrados com estatísticas táticas detalhadas (via *FBref*). O processamento vai incluir o desenvolvimento de métricas calculadas, especificamente um algoritmo de *Rating Elo* dinâmico adaptado à Primeira Liga portuguesa e o cálculo de médias móveis exponenciais para capturar o momento de forma das equipas.

Protocolo de Validação Temporal: Para garantir a integridade dos resultados e evitar fuga de dados (*data leakage*), rejeita-se a validação cruzada aleatória tradicional (*K-Fold*). Em vez disso, irá ser adotada uma estratégia de Validação Temporal Estrita (*Walk-Forward Validation*), onde o treino utiliza exclusivamente dados cronologicamente anteriores à data do teste. As métricas de avaliação (Exatidão, *F1-Score* e *Log-Loss*) servirão assim para medir a capacidade de generalização para o futuro e não a simples memorização do passado.

4. Arquitetura Tecnológica e Ferramentas

Na definição do *stack* tecnológico a prioridade foi garantir a eficiência no processamento de dados e a total reprodutibilidade dos resultados. Procurámos também ferramentas que oferecessem implementações fiáveis e já testadas dos algoritmos de Machine Learning.

Este capítulo descreve o conjunto de software utilizado ao longo de todo o projeto, cobrindo desde a fase inicial de extração de dados (*web scraping*) até à validação experimental dos modelos.

4.1 Linguagem de Programação: *Python*

O desenvolvimento do projeto assentou integralmente na linguagem *Python* (versão 3.13). A escolha do Python foi pragmática: é a 'língua franca' da Ciência de Dados. Tentar fazer isto em *Java* ou *C#* seria reinventar a roda, visto que todo o ecossistema de *Machine Learning* (XGBoost, Scikit-learn) é nativo em Python. Esta característica revelou-se crítica, uma vez que o processamento vetorial de datasets estruturados e o treino iterativo de modelos de *Gradient Boosting* exigem uma eficiência de baixo nível que o *Python* "puro" não conseguiria oferecer isoladamente.

A decisão de optar pelo Python, em detrimento de alternativas como R, Java ou MATLAB, fundamentou-se em quatro requisitos técnicos que validámos durante a fase de análise. O primeiro fator decisivo foi o acesso imediato ao estado da arte em *Machine Learning*. Como o nosso objetivo passava por utilizar algoritmos de *Gradient Boosting* altamente otimizados (como o *XGBoost* e o *LightGBM*), precisávamos de um ambiente onde a integração fosse nativa. Isto permitiu-nos focar na otimização dos hiperparâmetros e na estratégia de modelação, em vez de dispersarmos recursos a implementar algoritmos de raiz.

Do ponto de vista da gestão de dados, o Python revelou-se insubstituível tanto na recolha como no processamento. Dada a inexistência de fontes públicas com métricas avançadas (como os *Expected Goals*), tivemos de construir o nosso próprio *dataset* interagindo com plataformas web complexas. A biblioteca *Selenium* foi essencial para superar as barreiras de conteúdos dinâmicos e renderização de JavaScript, algo difícil de atingir com *parsers* tradicionais. Posteriormente, a biblioteca *Pandas* permitiu operacionalizar todo o processo de ETL, facilitando a fusão de ficheiros CSV estáticos com os dados recolhidos na web. Esta capacidade de limpar e alinhar estruturas de dados complexas garantiu a integridade da informação com uma simplicidade de código que seria impraticável em linguagens como Java ou C++.

Por fim, a escolha alinha o projeto com a reprodutibilidade científica. A predominância do Python na literatura académica sobre previsão desportiva significa que, ao utilizarmos o mesmo ecossistema tecnológico citado nos trabalhos relacionados, facilitamos a comparação direta e transparente dos nossos resultados face aos *baselines* académicos estabelecidos.

4.2 Bibliotecas de Software

A seleção das bibliotecas seguiu uma lógica funcional, agrupando-se as ferramentas de acordo com a sua responsabilidade no *pipeline* de *Machine Learning*: extração, processamento, modelação e avaliação.

4.2.1 Recolha e Automação: *Selenium*

A extração de dados do *website FBref* apresentou um desafio técnico particular: o site utiliza *JavaScript* para renderizar o conteúdo dinamicamente e possui mecanismos de proteção contra *bots*. As abordagens baseadas em requisições *HTTP* estáticas (como *requests* ou *BeautifulSoup*) revelaram-se insuficientes, pois não executavam os *scripts* necessários para popular as tabelas de estatísticas avançadas como os *Expected Goals*.

Para superar esta limitação, foi implementada uma solução de automação de navegador utilizando a biblioteca *Selenium* e o *driver* do Google Chrome. O módulo de extração (*scraper*) foi desenhado para simular a interação de um utilizador real, operando num navegador *headless* que utiliza condições de espera explícitas para garantir o carregamento completo do *DOM* antes de iniciar a recolha. Além da sincronização temporal, o sistema inclui lógica robusta para gerir sessões e lidar com exceções, detetando e fechando automaticamente *pop-ups* de consentimento (RGPD) ou janelas de *cookies* que poderiam interromper o fluxo de extração.

Esta estratégia permitiu-nos iterar sequencialmente sobre todas as épocas da Primeira Liga portuguesa, de 2005 a 2025, extraindo e estruturando o código *HTML* das 12 tabelas estatísticas disponíveis por jogo. O resultado final foi a construção de um *dataset* proprietário com um nível de granularidade inexistente em fontes públicas estáticas, estabelecendo assim a base fundamental para a nossa engenharia de atributos.

4.2.2 Processamento e Engenharia de Atributos: *Pandas* e *NumPy*

O tratamento dos dados brutos e a engenharia de características assentaram nas bibliotecas *Pandas* e *NumPy*. Estas ferramentas foram essenciais para manipularmos as estruturas tabulares de forma eficiente.

O *Pandas* assumiu-se como o núcleo do nosso *pipeline* de transformação (ETL). O desafio de gerir um *dataset* unificado com mais de 4400 jogos obrigou a uma gestão cuidada da memória e dos tipos de dados durante a ingestão. Mais do que a simples leitura, esta biblioteca foi crucial para a normalização e limpeza: foram implementas correções de inconsistências na nomenclatura das equipas (unificando, por exemplo, "Sporting CP" e "Sporting" numa chave única) e foram definidas estratégias para tratar valores em falta.

Além disso, o *Pandas* permitiu criar variáveis dinâmicas fundamentais, como a "forma recente", recorrendo a janelas deslizantes (*rolling windows*) e operações de agrupamento que capturam a sequência temporal dos resultados. Foi também através desta ferramenta que realizámos a fusão das estatísticas táticas do *FBref* com os dados de mercado, garantindo o alinhamento correto entre fontes distintas.

Complementarmente, recorremos ao *NumPy* para assegurar a eficiência computacional das operações matemáticas de baixo nível. A utilização de estruturas *ndarray* (vetores N-dimensionais) permitiu realizar a manipulação necessária para converter os dados processados num formato compatível com o *XGBoost*, garantindo um desempenho de processamento muito superior ao que teríamos obtido com as listas nativas do *Python*.

4.2.3 Modelação e Tratamento de Desequilíbrio: *Scikit-learn* e *Imbalanced-learn*

A implementação dos modelos preditivos e das rotinas de avaliação teve como base a biblioteca *Scikit-learn*, complementada por técnicas específicas para corrigir o desequilíbrio de classes. Esta biblioteca forneceu a infraestrutura essencial tanto para a criação de *baselines* comparativos (como a Regressão Logística) quanto para o pré-processamento dos dados, incluindo a divisão entre treino e teste e a codificação de variáveis. Neste processo, é possível destacar o desempenho do *Random Forest Classifier*, que se revelou particularmente eficaz a identificar a classe minoritária (Empate). Ao atingir um *recall* de 48% nesta categoria, este modelo estabeleceu uma referência de qualidade crucial para a calibração do modelo principal.

Para atacar o problema em prever empates (estatisticamente o resultado menos frequente), foi integrada a biblioteca *Imbalanced-learn*. No entanto, foram rejeitadas técnicas rudimentares de simples duplicação de dados, optando antes pela aplicação de *SMOTE* (*Synthetic Minority Over-sampling Technique*). Em vez de repetir informação, esta abordagem gera exemplos sintéticos através de interpolação no espaço de características. Isto permite enriquecer o conjunto de treino com dados novos e plausíveis, ajudando o modelo a definir fronteiras de decisão mais robustas para a classe intermédia, sem cair no erro de *overfitting* por memorização.

4.2.4 Motor de Inferência: XGBoost

O algoritmo **XGBoost** (*eXtreme Gradient Boosting*) foi selecionado como o núcleo do sistema preditivo, dada a sua validação no estado da arte como a solução mais eficiente para dados tabulares estruturados [23]. Contudo, a sua implementação exigiu configurações técnicas específicas para responder às necessidades do domínio das apostas.

Uma decisão crítica foi a definição da função objetivo como *multi:softprob*. Esta configuração é vital para o projeto, pois altera a natureza da saída do modelo: em vez de nos devolver apenas uma classe (vitória, empate ou derrota), fornece-nos um vetor de probabilidades para cada desfecho. Estes valores percentuais são a matéria-prima essencial para calcularmos o Valor Esperado e identificarmos oportunidades de aposta reais.

No entanto, as primeiras iterações revelaram um desafio técnico grave: um *overfitting* massivo, onde o modelo atingia 95% de precisão no treino, mas caía para 52% nos dados de teste.

Para corrigir esta variância e impedir que o modelo se limitasse a memorizar o passado, foi implementada uma estratégia de otimização usando *GridSearchCV*. Este processo permitiu ajustar sistematicamente os hiperparâmetros como a profundidade das árvores (*max_depth*) e a taxa de aprendizagem (*learning_rate*), maximizando a capacidade de generalização e minimizando a função de perda (*Log-Loss*) em dados que o modelo nunca tinha visto.

4.2.5 Visualização de Dados: Matplotlib e Seaborn

A visualização de dados não serviu apenas para ilustrar o relatório, funcionou como uma ferramenta de diagnóstico essencial para validarmos hipóteses e compreendermos o comportamento interno dos modelos. Para tal, combinámos duas bibliotecas complementares.

Foi utilizado o *Matplotlib* sempre que foi preciso um controlo de "baixo nível" sobre os elementos gráficos, permitindo-nos personalizar cada detalhe das figuras finais. Por outro lado, o *Seaborn* foi a ferramenta de eleição para a Análise Exploratória de Dados (*EDA*) e avaliação de performance.

O seu papel foi crítico na geração de mapas de calor (*heatmaps*) para as Matrizes de Confusão. Foi precisamente através destas visualizações que foi possível detetar o enviesamento inicial do *XGBoost*, que tendia a subestimar drasticamente a probabilidade de empate. Este diagnóstico visual foi a prova concreta que fundamentou a decisão técnica de introduzir o algoritmo *SMOTE* no nosso *pipeline*.

Para sistematizar as escolhas técnicas detalhadas ao longo deste capítulo, a Tabela 2 resume o ecossistema de software utilizado, identificando a função e a motivação estratégica de cada ferramenta.

Tabela 2 Resumo do Ecossistema Tecnológico

Categoria	Ferramenta / Biblioteca	Função Principal no Projeto	Motivação Principal
Linguagem	***Python* 3.13**	Base de todo o desenvolvimento.	Padrão da indústria, bibliotecas ricas.
Recolha de Dados	***Selenium***	Automação de *browser* para *scraping*.	Contornar proteções do *FBref* e *JavaScript*.
	Pandas	Leitura/Escrita de *CSVs* e integração.	Manipulação eficiente de *datasets* complexos.
Manipulação	***Pandas* / *NumPy***	Limpeza e engenharia de *features*.	Tratamento de dados, *arrays* numéricos.
Modelação	***XGBoost***	Algoritmo principal (*Gradient Boosting*).	Estado da arte para dados tabulares.

	Scikit-learn	*Baselines*, métricas e divisão de dados.	*API* padrão, modelos de comparação (*RF*, *LogReg*).
Otimização	***Imbalanced-learn***	Aplicação de *SMOTE*.	Resolução do problema de desequilíbrio (empates).
Visualização	***Matplotlib* / *Seaborn***	Gráficos de *EDA* e avaliação.	Interpretação visual de erros (Matriz de Confusão).
Ambiente	***Jupyter Notebook***	Prototipagem e análise exploratória.	Desenvolvimento interativo e documentado.
Gestão	***GitHub***	Controlo de versões e diário.	Segurança, histórico e organização.
Bibliografia	***Zotero***	Gestão de referências bibliográficas.	Organização rigorosa da revisão de literatura.

4.3 Ambiente de Desenvolvimento

Para a fase de testes, o *Jupyter Notebook* foi insubstituível. A capacidade de correr células isoladas permitiu-me afinar os gráficos e testar features novas sem ter de re-treinar o modelo todo cada vez que mudava uma vírgula.

4.3.1 Prototipagem e Análise: *Jupyter Notebook*

A adoção do *Jupyter Notebook* baseou-se em duas vantagens operacionais que aceleraram drasticamente o desenvolvimento. Primeiro, a sua arquitetura baseada em células permitiu criar ciclos de *feedback* extremamente rápidos.

Na prática, foi executado e testado blocos de código isolados como uma função de pré-processamento e visualizar o resultado imediato, sem a necessidade de reexecutar todo o *pipeline* de dados desde o início a cada pequena alteração.

Em segundo lugar, a persistência de estados revelou-se decisiva para a gestão de recursos. Como o *Jupyter* preserva os *outputs* (gráficos, tabelas e *logs*) no próprio ficheiro, tornou-se possível analisar os resultados de forma assíncrona. Isto é vital quando lidamos com processos computacionalmente pesados, como a otimização de hiperparâmetros (GridSearch) do *XGBoost*: uma vez terminado o treino, os resultados ficam "gravados" visualmente, evitando o custo de reprocessar horas de cálculo apenas para verificar uma métrica ou rever um gráfico.

4.3.2 Controlo de Versões e Documentação: GitHub

A gestão do código e a documentação de todo o projeto foi centralizada na plataforma *GitHub*. O repositório serviu não apenas para o controlo de versões, mas como um registo vivo da evolução técnica do sistema.

A estrutura de ficheiros foi organizada para refletir a própria arquitetura lógica do projeto, garantindo uma separação clara entre os diferentes componentes: os

dados (divididos em pastas *Datasets/Raw* para os originais e *Datasets/Processed* para os tratados), o código experimental (*Notebooks/*) e a documentação técnica de apoio (*DICIONARIO_DADOS.md*).

Um dos pontos mais importantes desta gestão foi a rastreabilidade das decisões. Foi mantido um registo técnico contínuo num ficheiro dedicado (*diario.md*). Este documento funciona como um diário de desenvolvimento, onde foram registadas cronologicamente decisões de arquitetura, a evolução dos hiperparâmetros e, crucialmente, as falhas nas tentativas de otimização. Esta prática assegura a total transparência do processo de investigação, permitindo compreender não só o resultado final, mas todo o raciocínio e experimentação que levaram até ele.

4.3.3 Gestão Bibliográfica: Zotero

Para garantir o rigor académico e a gestão das fontes citadas no trabalho relacionado, utilizou-se o software *Zotero*. Esta ferramenta foi fundamental para sistematizar toda a bibliografia técnica e científica, assegurando não só a normalização automática das citações, mas também a integridade das referências que fundamentam as nossas escolhas algorítmicas ao longo do projeto.

5. Implementação e Análise Experimental

Um modelo de *ML* é tão bom quanto os dados que consome. Por isso, a maior parte do esforço deste projeto não foi a afinar hiperparâmetros, mas sim a construir um pipeline de dados que transformasse estatísticas brutas em sinais de qualidade.

Reconhecendo a elevada variância inerente ao futebol, onde a equipa com melhor desempenho nem sempre vence, a estratégia experimental afastou-se de uma previsão baseada exclusivamente em resultados passados. Em vez disso, foi privilegiada a extração de indicadores de desempenho subjacentes (*underlying metrics*). Estes indicadores oferecem uma representação mais fiel da qualidade tática e da consistência das equipas a longo prazo, reduzindo o ruído provocado por fatores aleatórios num único jogo.

5.1 Arquitetura de Aquisição e Processamento de Dados (ETL)

Como a performance de qualquer modelo preditivo depende diretamente da qualidade dos dados, foi desenvolvido um processo de *ETL* (*Extract*, *Transform*, *Load*) focado na consistência da informação da Primeira Liga portuguesa.

A recolha de dados foi feita através de *web scraping*. Em vez de depender de datasets públicos, que geralmente são limitados, foram criados extratores personalizados. Isto permitiu captar não só os resultados finais, mas também estatísticas detalhadas (como posse de bola, remates e eficácia de passe), enriquecendo significativamente as variáveis disponíveis para o algoritmo.

O processamento seguiu critérios rigorosos para resolver dois problemas comuns:

1. **Tratamento de Ruído:** O foco esteve na normalização dos nomes das equipas (que variam ao longo das épocas) e na correção de registos incompletos para evitar distorções.
2. **Prevenção de *Data Leakage*:** A prioridade foi respeitar a linha temporal. O sistema garante que, para prever um jogo numa data, o modelo acede apenas a informações anteriores a esse momento. Qualquer dado que contivesse informações "do futuro" (do próprio jogo) foi retirado.

No final, esta preparação converteu dados não estruturados numa base tabular organizada, pronta para a fase de treino e validação.

5.1.1 Seleção das Fontes de Dados (FBRef e football-data.co.uk)

A escolha das fontes de dados baseou-se em três pilares: nível de detalhe estatístico, histórico disponível e a possibilidade de automatizar a recolha. Após testar algumas *APIs* comerciais (descartadas pelos limites restritivos das versões gratuitas) e repositórios estáticos como o *Kaggle*, escolheu-se seguir uma abordagem híbrida conjugando o *FBRef* e o *Football-Data.co.uk*. Esta estratégia dupla permite cruzar a performance desportiva detalhada (via FBRef) com dados de mercado e odds (via Football-Data), criando um dataset mais robusto.

- **FBRef: Métricas de *Advanced Analytics***

O FBRef foi escolhido como fonte primária por disponibilizar métricas avançadas (*Advanced Analytics*) para a Primeira Liga portuguesa. Estes dados, disponíveis a partir da época 2017-2018, são fundamentais para avaliar a qualidade de jogo para lá do resultado final, reduzindo o ruído dos marcadores:

1. ***Expected Goals* (xG):** Avalia a qualidade das oportunidades criadas, sendo uma métrica mais estável que os golos reais para prever desempenho futuro.
2. ***Shot/Goal-Creating Actions* (SCA/GCA):** Medem o volume ofensivo e a capacidade de construção, independentemente de a bola entrar ou não.
3. **Métricas de Posse e Progressão:** Ajudam a identificar o perfil tático e o domínio territorial das equipas.

O processo de extração focou-se em 12 tabelas específicas (como *Standard Stats*, *Goalkeeping* e *Shooting*) para construir o perfil de cada equipa.

Do ponto de vista técnico, extrair dados do *FBRef* é desafiante. O site esconde tabelas dentro de comentários *HTML* e possui mecanismos *anti-bot*. Isso inviabilizou o uso de bibliotecas simples de pedidos *HTTP* (como o *requests*). A solução passou por desenvolver um *scraper* baseado em automação de browser, o que permite carregar a página completamente e extrair os dados de forma estruturada e fiável.

- **Football-Data.co.uk: Dados Estruturais e de Mercado**

Para complementar as métricas avançadas do FBRef, integrei o repositório Football-Data.co.uk como a estrutura base do dataset. A grande vantagem desta fonte é a consistência dos ficheiros CSV, o que minimizou o trabalho de pré-processamento.

Como é possível observar na Tabela 3, que compara as características técnicas das duas fontes, o Football-Data.co.uk distingue-se por fornecer dados já estruturados e prontos a usar. No contexto deste projeto, esta fonte desempenha três papéis fundamentais:

1. **Definição do *Ground Truth*:** É a fonte oficial para as variáveis que queremos prever (o resultado final e os golos).
2. **Incorporação de Dados de Mercado:** Fornece as odds de fecho (*closing odds*) de várias casas de apostas. No modelo, utilizei estas odds como *features* informativas. A lógica é simples: as odds acabam por agregar dados qualitativos externos (como lesões de última hora ou motivação das equipas) que o mercado já processou, funcionando como indicadores indiretos de informação que as estatísticas de jogo puras não captam.
3. **Estatísticas Intra-Jogo:** Garante métricas padronizadas (Remates, Cantos, Cartões) essenciais para medir a forma recente das equipas.

Ao analisar o histórico, é visível uma inconsistência na qualidade dos dados: antes de 2003, os registos resumiam-se muitas vezes apenas ao resultado final.

Para manter a coerência do vetor de características (*feature vector*), decidi restringir o treino apenas às épocas onde existe uma interseção completa entre o FBRef e o Football-Data. Isto evitou ter de recorrer ao preenchimento artificial (imputação) de dados em variáveis críticas.

Tabela 3 Análise comparativa técnica e funcional entre as fontes de dados

Características	FBRef	Football-Data.co.uk
Tipo de dados	Estatísticas Agregadas por Temporada	Eventos de Jogos e Odds por Partida
Formato de Origem	HTML	CSV Estruturado
Granularidade	**Alta** (xG, SCA, Posse)	**Média** (Remates, Cantos, Cartões)
Profundidade Histórica	> 20 Épocas (Variável por tabela)	Desde 1994/1995 (Primeira Liga portuguesa)
Barreira de Acesso	Elevadas (Proteção Anti-Bot, Rate Limits)	Nulas (Dados Abertos)
Função no Modelo	*Features* de Contexto (Histórico da Época N-1)	*Features* de Jogo e Variável Alvo (Target)

5.1.2 Limpeza, Resolução de Entidades e Integração Temporal

O objetivo central desta fase de *ETL* foi unificar as duas fontes de dados heterogéneas (*Football-Data e FBRef*) num dataset analítico coerente. Recorrendo à biblioteca pandas, o trabalho focou-se na normalização de tipos, na harmonização de nomes e na fusão temporal correta.

- **Pré-processamento e Normalização**

A higienização inicial incidiu sobre a estrutura dos dados:

1. **Série Temporal:** A prioridade foi a conversão de todas as datas para objetos *datetime* e a ordenação cronológica rigorosa do *dataframe*. Como veremos mais à frente na secção de validação, esta ordenação é um pré-requisito obrigatório para aplicar a estratégia de *Walk-Forward* e para o cálculo de janelas deslizantes (*rolling windows*).
2. **Redução de Ruído:** Foram removidas colunas de metadados irrelevantes e artefactos de exportação, mantendo apenas as variáveis com valor preditivo.

- **Resolução de Entidade (*Entity Resolution*)**

A integração foi o maior pesadelo técnico. O 'Sp Lisbon' num ficheiro era 'Sporting CP' noutro. Para resolver isto, não confiei em algoritmos de similaridade de *strings* (que podem falhar). Em vez disso, foi implementado um dicionário de mapeamento manual. Esta abordagem garantiu uma correspondência exata entre as fontes, eliminando erros de junção que poderiam duplicar ou perder registos de jogos.

- **Lógica de Integração Temporal ($N-1$)**

A estrutura dos dados foi desenhada para garantir que respeitamos a linha do tempo, evitando qualquer tipo de *data leakage*. A lógica é simples: as métricas de qualidade do FBRef (como xG e Posse) são integradas como contexto histórico. Ou seja, para o modelo prever um jogo da época atual (N), ele recebe como entrada o perfil de desempenho que a equipa teve na época anterior ($N-1$).
Tecnicamente, a fusão foi feita através de *Left Joins* (para a equipa da casa e visitante), usando a chave composta (Equipa + Época Anterior). O resultado estrutural pode ser visualizado na Tabela 4.

Tabela 4 Exemplo da estrutura após integração temporal (Contexto N-1)

Data	Equipa_Casa	Equipa_Visitante	Home_hist_xG (N-1)	Away_hist_xG (N-1)
13/08/2023	Sporting CP	Vizela	74 (4º em 22/23)	38.5 (11º em 22/23)
13/08/2023	Moreirense	FC Porto	NaN (Promovido)	85 2º em 22/23)

- **Imputação de Dados para Equipas Promovidas**

Como se observa na linha do Moreirense na Tabela 4, a lógica gera valores nulos (*NaN*) para equipas recém-promovidas, pois estas não têm registo na Primeira Liga no ano anterior. Simplesmente excluir estes registos seria um erro, pois implicaria perder cerca de 15% da amostra total.

Para resolver isto sem eliminar dados, implementei uma estratégia de imputação baseada no conhecimento do domínio. Assumi a premissa de que o perfil estatístico de uma equipa que acaba de subir é, na maioria das vezes, semelhante ao das equipas que lutam para não descer.

Assim, o algoritmo calcula a média das métricas (*xG*, Pontos, Golos Sofridos) das três piores equipas da época anterior. Estes valores médios que representam um "perfil de fundo de tabela" são usados para preencher os dados em falta das equipas promovidas. Isto permite ao modelo fazer previsões sobre novos competidores sem introduzir ruído artificial excessivo.

- **Consolidação Final**

A etapa final foi apenas de limpeza e organização: renomeei as variáveis para tornar a leitura mais intuitiva (ex: *FTHG* passou a Golos_Casa_Final). O resultado é um *dataset* contínuo e temporalmente coerente, combinando eventos de jogo, odds de mercado e métricas avançadas, estando agora pronto para o treino dos algoritmos.

5.2 Análise Exploratória de Dados

A fase de Análise Exploratória de Dados teve como grande objetivo validar o dataset final (*dataset_final_merged_v2.csv*) antes de avançar para a modelação. Esta validação foi crítica para garantir que os processos de pré-processamento, especificamente a imputação de dados nas equipas promovidas e a fusão temporal, não introduziram erros ou ruído estatístico que pudessem comprometer os algoritmos.

O dataset consolidado cobre um horizonte de 13 épocas (de 2010/11 a 2023/24), totalizando 4.425 jogos e 310 variáveis. Devido a esta elevada dimensionalidade, a análise ultrapassou a estatística descritiva simples, articulando-se em três eixos técnicos. Inicialmente, procedeu-se à deteção de anomalias, verificando *outliers* e inconsistências decorrentes da integração entre o *Football-Data.co.uk* e o *FBref*. De seguida, realizou-se a análise de distribuição para avaliar a assimetria (*skewness*) e curtose das variáveis, passo essencial para determinar a necessidade de transformações (como *scaling* ou logaritmos) em modelos sensíveis à escala.

Por fim, a seleção preliminar de *features* focou-se nas correlações lineares e não-lineares para identificar os atributos com maior poder discriminativo face às três classes alvo. Esta etapa permitiu filtrar variáveis redundantes e validar a hipótese de que métricas de segunda ordem, como o xG ou as Odds de mercado, possuem uma correlação mais forte com o resultado final do que os indicadores estatísticos simples [25].

5.2.1 Análise Univariada e Distribuição das Classes

Na análise univariada, começou-se por caracterizar estatisticamente as variáveis, dando prioridade máxima à variável alvo, ou seja, ao *Resultado_Final*. O objetivo foi identificar desde logo desequilíbrios que pudessem condicionar a escolha dos algoritmos ou a forma como medimos o erro.

- **Distribuição da Variável Alvo e Desequilíbrio de Classes**

Como a variável dependente tem três desfechos possíveis (Vitória da Casa, Empate, Vitória do Visitante), a primeira coisa que salta à vista no histograma da Figura 2 é a confirmação do famoso "fator casa" na Primeira Liga portuguesa. Existe um desequilíbrio estrutural claro no dataset.

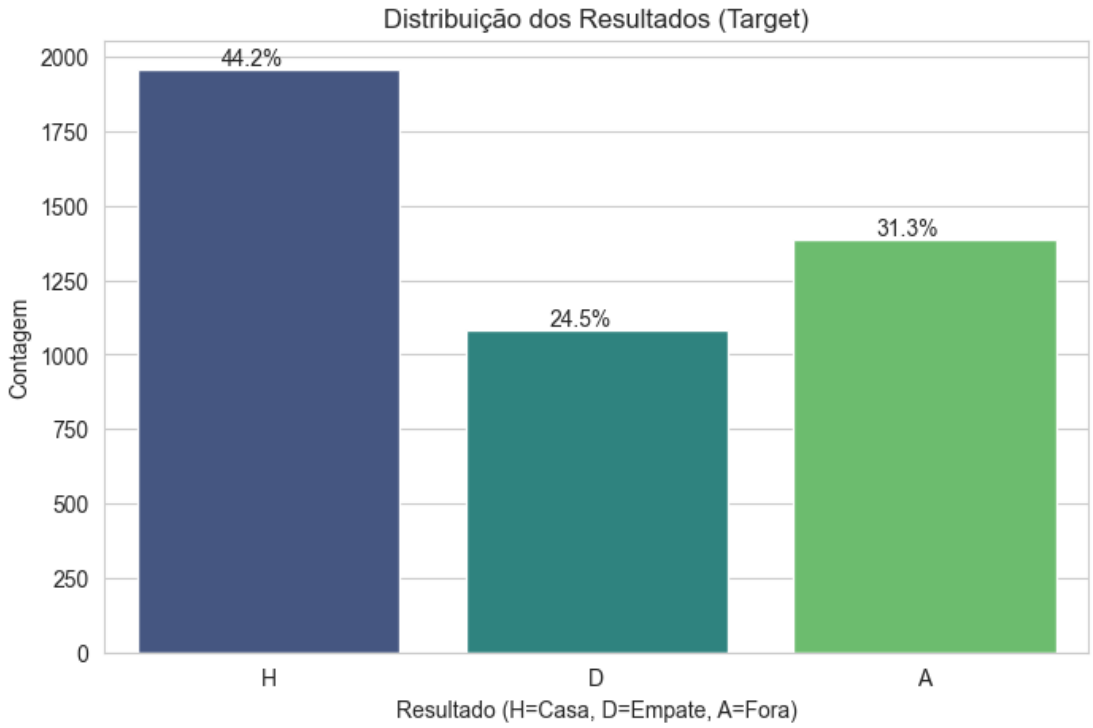

Figura 2 Histograma da distribuição das classes H/D/A

Ao analisar os números em detalhe na Tabela 5, percebe-se que o Empate é a classe minoritária, representando apenas cerca de 24% dos jogos. Isto traz duas consequências práticas imediatas para o projeto. Primeiro, define a "linha de base": um modelo ingénuo (o chamado *ZeroR*) que aposte cegamente sempre na vitória da casa já acerta 44,25% das vezes. Portanto, qualquer modelo inteligente superar obrigatoriamente este valor para ter alguma utilidade real.

Segundo, os testes iniciais mostraram que, sem ajustes, algoritmos como o *XGBoost* tendem a ignorar os empates por serem menos frequentes, focando-se apenas nas vitórias. Este facto provou ser necessário aplicar pesos nas classes (*class weights*) ou técnicas de reamostragem (como o SMOTE) durante o treino, para garantir que o modelo não fica enviesado e aprende efetivamente a prever os três resultados.

Tabela 5 Quantificação do desequilíbrio de classes no conjunto de dados total

Classe	Descrição	Contagem Absoluta	Frequência Relativa
H	Vitória da Casa	1958	44.25%
A	Vitória do Visitante	1385	31.30%
D	Empate	1082	24.45%

- **Análise das Variáveis Numéricas de Performance**

A análise das variáveis contínuas, como os Pontos e o xG, serviu essencialmente para entender a forma das distribuições e detetar valores anómalos que pudessem confundir o modelo.

- **Histórico de Pontos e Assimetria:** Ao observar o histórico de pontos das equipas da casa na Figura 3, nota-se imediatamente uma distribuição com assimetria positiva (a chamada "cauda longa" à direita). Isto não é um defeito dos dados, mas sim o reflexo fiel da realidade da Primeira Liga portuguesa: existe um fosso competitivo enorme, onde um grupo muito restrito de equipas acumula pontuações muito superiores à média do campeonato.

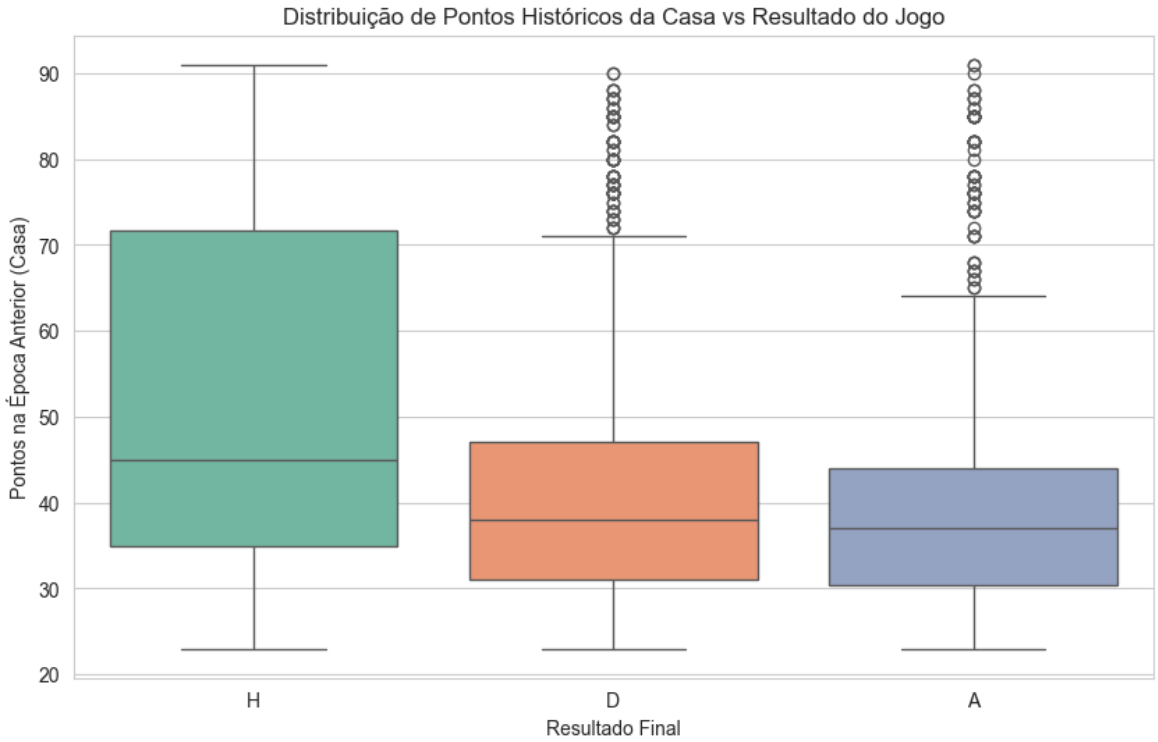

Figura 3 Distribuição da média de pontos históricos das equipas da casa

- **Validação da Imputação (xG):** Relativamente aos *Expected Goals* (xG), utilizei a dispersão apresentada na Figura 4 para verificar se a imputação de dados que foi feita para as equipas promovidas não tinha sido criado usando dados falsos ou irreais.

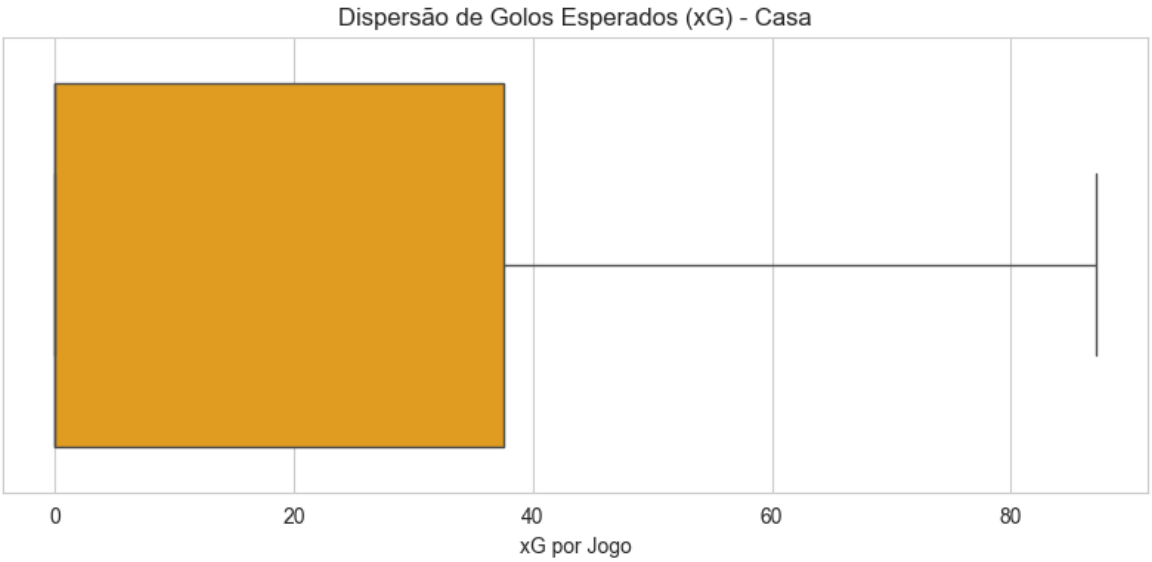

Figura 4 Dispersão dos Golos Esperados (xG) históricos por jogo

Os dados confirmam que a estratégia funcionou. Os valores que imputei (baseados na média das equipas da zona de despromoção) caem exatamente onde seria de esperar: no primeiro quartil da distribuição, ou seja, entre as equipas com menor produção ofensiva. Não se verificaram picos artificiais nos gráficos, o que valida a estratégia como estatisticamente coerente.

- **Distribuição das Odds de Apostas:** Por fim, analisei as variáveis associadas às *odds*, que seguem também uma distribuição de cauda longa. Mas o mais interessante surge quando cruzamos estes dados com o resultado real do jogo.

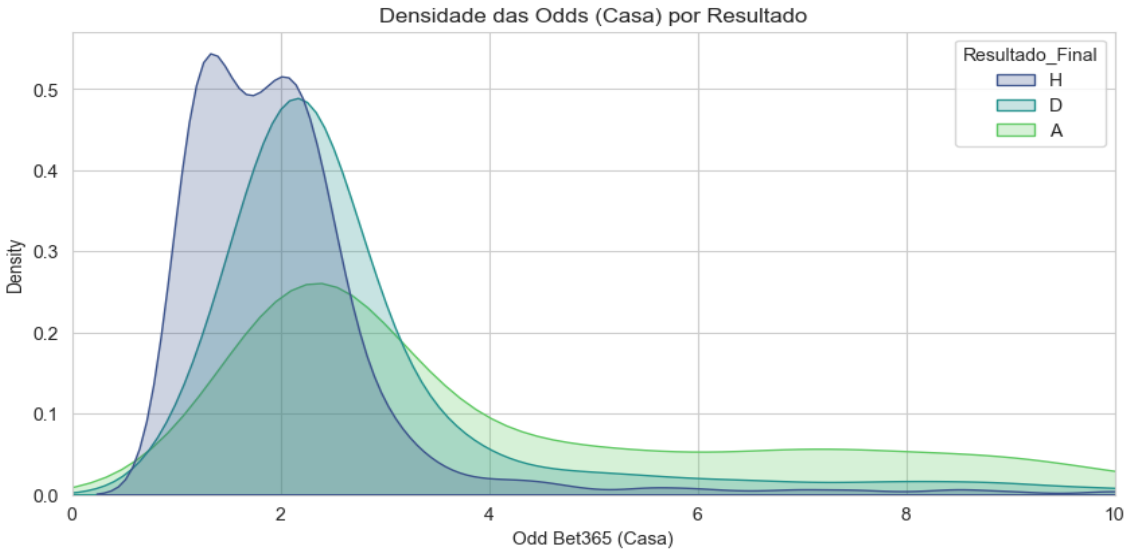

Figura 5 Distribuição das Odds da equipa da casa (Odd_Casa_Bet365) condicionada pelo resultado final

Ao observar a Figura 5, que mostra a distribuição das *odds* condicionada pelo resultado final, conseguimos validar visualmente a eficiência do mercado. Vemos

claramente uma grande concentração de vitórias da casa (H) quando as *odds* são baixas (entre 1.10 e 1.50) — ou seja, quando a casa de apostas diz que é "fácil", geralmente a equipa ganha mesmo.

5.2.2 Análise de Correlação e Identificação de Padrões

Era necessário limpar o ruído. Se duas variáveis dizem exatamente a mesma coisa, ter as duas só confunde o modelo. Usei a correlação para eliminar estas redundâncias. Este passo é crítico para limpar o modelo, pois ter dados redundantes não só torna o cálculo mais lento como pode confundir a interpretação, especialmente em modelos lineares.

- **Matriz de Correlação de Pearson**

Tendo em conta que o *dataset* tem uma quantidade enorme de variáveis, seria impossível analisar tudo de uma vez. Por isso, foi feita uma restrição a análise de correlação (Pearson) a um subconjunto de "pesos pesados": histórico de pontos, forma recente, xG e as Odds de mercado

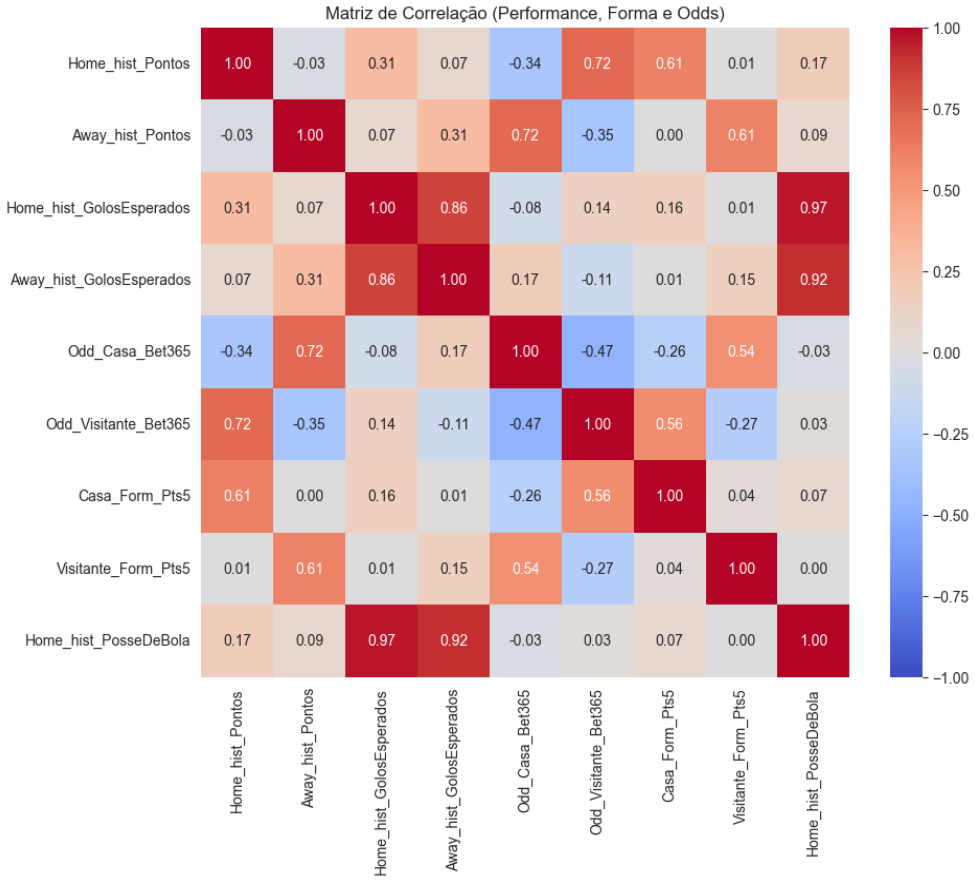

Figura 6 Matriz de Correlação (Performance, Forma, Odds)

Ao analisar a Figura 6, saltam à vista dois padrões estruturais que influenciam diretamente a seleção das *features*:

1. **Redundância entre Pontos e Odds:** Existe uma correlação negativa clara entre o histórico de pontos e as odds da casa. Ou seja, equipas com melhor performance têm, consistentemente, odds mais baixas (o que faz sentido). Isto sugere que as *odds* de fecho já "sabem" e incorporam o histórico da época. Levanta-se aqui uma questão interessante: em modelos lineares, usar as duas variáveis pode ser redundante, mas acredito que modelos de *ensemble* (como o XGBoost) ainda consigam extrair valor das pequenas divergências entre a performance real e o que a casa de apostas diz.
2. **Consistência do xG:** A forte correlação positiva entre o *xG* acumulado e os Pontos valida a métrica. Confirma que o *Expected Goals* não é apenas um número abstrato, mas um indicador robusto da qualidade real da equipa a longo prazo.

- **Separabilidade de Classes: Métricas Avançadas**

Para ir além das correlações lineares simples, analisou-se se as métricas ofensivas eram capazes de desenhar fronteiras entre quem ganha e quem perde. Para isso, analisei a interação entre os dados de construção de jogo, visualizados no *scatter plot* da Figura 7.

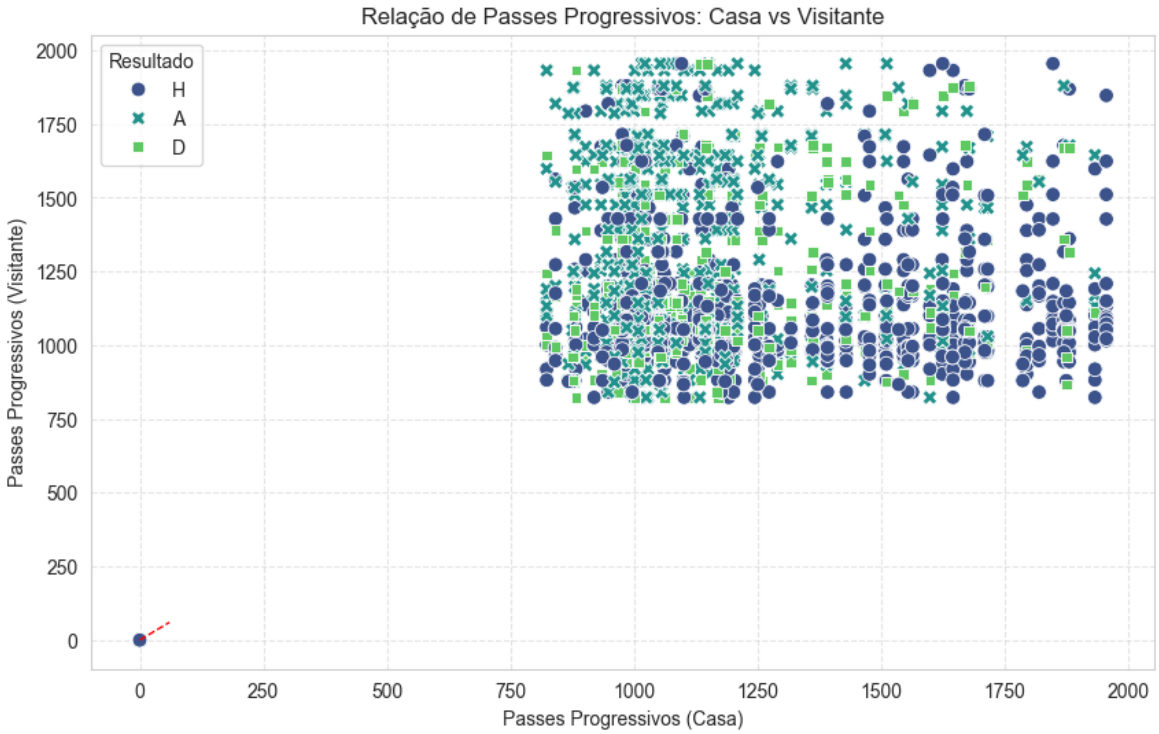

Figura 7 Relação entre a média de passes progressivos das equipas em confronto

A conclusão visual é bastante intuitiva. Ao olharmos para as extremidades do gráfico, a separação é clara, com as vitórias da casa a concentrarem-se na zona onde a equipa anfitriã domina inequivocamente os passes. Contudo, na zona central, o cenário muda drasticamente e vemos uma sobreposição densa das três classes, com muitos empates à mistura. Esta "mancha" central ilustra perfeitamente o desafio deste projeto: em jogos equilibrados, olhar apenas para o volume ofensivo

não chega para distinguir o vencedor. É exatamente nesta zona de incerteza que o modelo terá de encontrar padrões mais subtis do que apenas "quem ataca mais".

- **Padrões Temporais: A Influência da "Forma"**

Para fechar a análise, foi feita a investigação do impacto da forma recente, especificamente os pontos conquistados nos últimos 5 jogos, no desfecho da partida atual. A ideia era perceber se o momento de uma equipa é, de facto, um bom preditor.

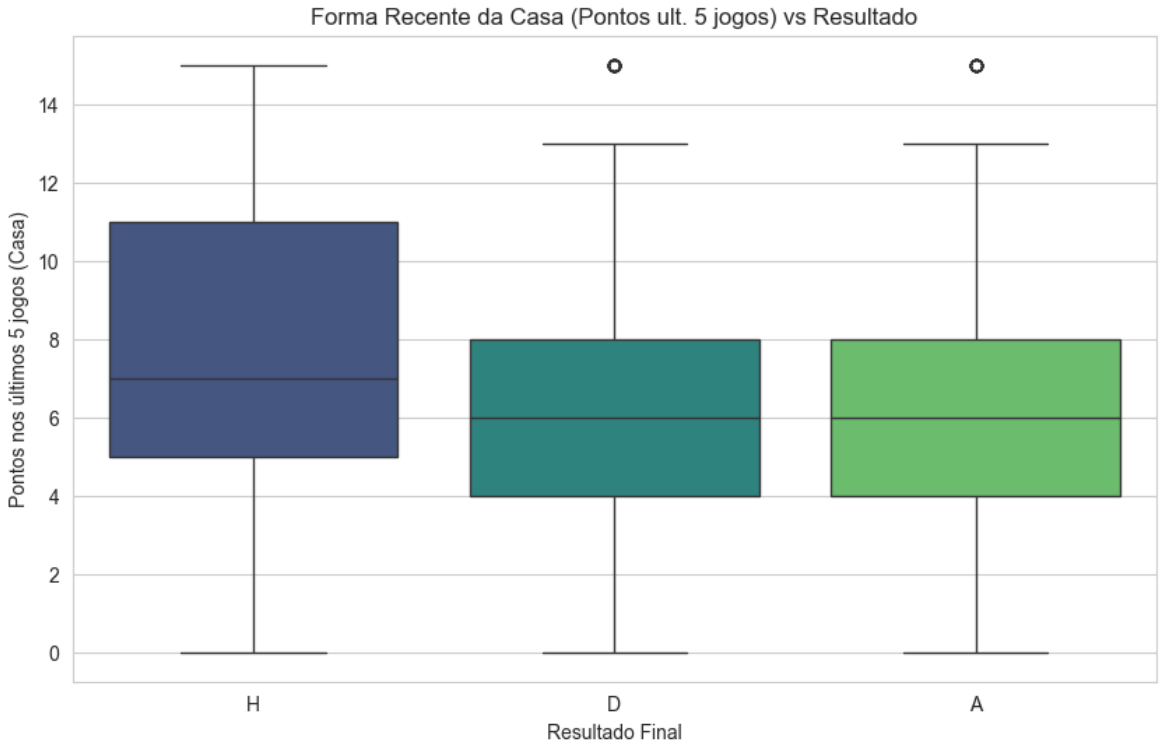

Figura 8 Impacto da forma recente (últimos 5 jogos) no resultado do jogo atual

Ao observar os diagramas de caixa (*boxplots*) na Figura 8, procurei sinais claros. Se as medianas das caixas de Vitória da Casa ('H') e Vitória do Visitante ('A') estiverem bem afastadas, isso confirma que a janela de 5 jogos é uma métrica eficaz para distinguir vencedores. Por outro lado, se as caixas se sobrepuserem demasiado, significa que esta "forma recente" tem muito ruído e talvez não diga assim tanto sobre o jogo seguinte. Esta incerteza visual sugere que o período de 5 jogos pode não ser o ideal, o que justifica testar janelas alternativas (como 3 ou 10 jogos) mais à frente, na fase de afinação do modelo.

- **Síntese da Análise Exploratória**

Em resumo, a Análise Exploratória confirmou que estamos perante um problema complexo. O espaço de características está marcado pelo desequilíbrio de classes (poucos empates) e pela redundância óbvia entre o que as *odds* dizem e o que a estatística histórica mostra. As evidências recolhidas, nomeadamente a dificuldade

em separar vencedores apenas pelo volume ofensivo e a forte correlação entre *odds* e performance, reforçam a necessidade de usar armas mais pesadas. Fica claro que modelos lineares simples não chegam; a estratégia terá de passar por modelos não-lineares como o *XGBoost* e técnicas de reamostragem (*SMOTE*) para "ensinar" o modelo a não ignorar os empates.

5.3 Engenharia de Atributos (*Feature Engineering*)

A Engenharia de Atributos assumiu o papel central na transformação dos dados, convertendo os registos brutos dos jogos em vetores numéricos que o modelo consegue interpretar. O grande desafio desta etapa foi traduzir a natureza imprevisível do futebol em dois eixos de informação concretos: a capacidade estrutural das equipas (a sua qualidade real a longo prazo) e a dinâmica temporal.

A estratégia adotada fundiu a profundidade analítica do FBRef com os dados de mercado do Football-Data.co.uk. Esta combinação foi essencial para ajudar os modelos a detetar padrões não-lineares, especialmente na previsão dos empates, que costumam ser o resultado mais difícil de antecipar. É importante notar que todo o processo respeitou rigorosamente o princípio da causalidade, garantindo que não existe qualquer fuga de informação do futuro para o passado (*data leakage*).

A Tabela 6 sistematiza as variáveis criadas no dataset final, dividindo-as em cinco famílias principais.

Tabela 6 Taxonomia das *Features Engineering* no Dataset Final

Família de Atributos	Prefixo / Identificador	Descrição e Justificação	Fonte Primária
Históricos	Home_hist_ / Away_hist	Métricas agregadas da época anterior (N−1). Definem o *baseline* de qualidade da equipa (ex: xG médio, Pontos/Jogo anteriores).	FBRef
Forma Recente	Casa_Form_ / Visitante_Form_	Janelas deslizantes (*rolling windows*) dos últimos 5 jogos. Capturam tendências de curto prazo, fadiga e *momentum*.	Calculado
Métricas Avançadas	GolosEsperados, PassesProgressivos	Indicadores de desempenho subjacente. Isolam a qualidade da criação de jogo da variância da finalização.	FBRef
Consenso de Mercado	Odd_ , Max, Avg	Probabilidades implícitas das casas de apostas. Funcionam como *proxy* para informação externa não estruturada (lesões, clima, motivação).	football-data.co.uk
Contexto do Jogo	Div, Season, Hora	Metadados para segmentação e validação temporal, excluídos do	Ambos

		treino para evitar *overfitting* a épocas específicas.	

5.3.1 Tratamento de Variáveis Categóricas e Identificadores

Como os algoritmos selecionados (tanto o XGBoost como o Random Forest) não "lêem" texto, exigindo representações estritamente numéricas, o tratamento das variáveis categóricas foi um passo obrigatório. O desafio foi preservar o significado dos dados sem criar uma matriz de treino demasiado complexa ou esparsa.

- **Codificação da Variável Alvo (Label Encoding)**

Para a variável mais importante do projeto, o Resultado Final (Vitória da Casa, Empate ou Vitória do Visitante) a solução passou por aplicar *Label Encoding*. Esta transformação é essencial para garantir a compatibilidade com a função de perda do *XGBoost* (*multi:softprob*).

Na prática, mapearam-se as classes para números inteiros simples: a Vitória do Visitante ('A') converteu-se em 0, o Empate ('D') em 1 e a Vitória da Casa ('H') em 2. É fundamental salientar que esta codificação numérica não confunde os modelos de árvore de decisão. Estes algoritmos interpretam os números 0, 1 e 2 apenas como categorias distintas para separar os ramos da árvore, e não como uma escala de valor onde o 2 valeria "o dobro" do 1. Desta forma, preserva-se a integridade estatística da classificação, tal como se pode visualizar na distribuição final apresentada na Figura 9.

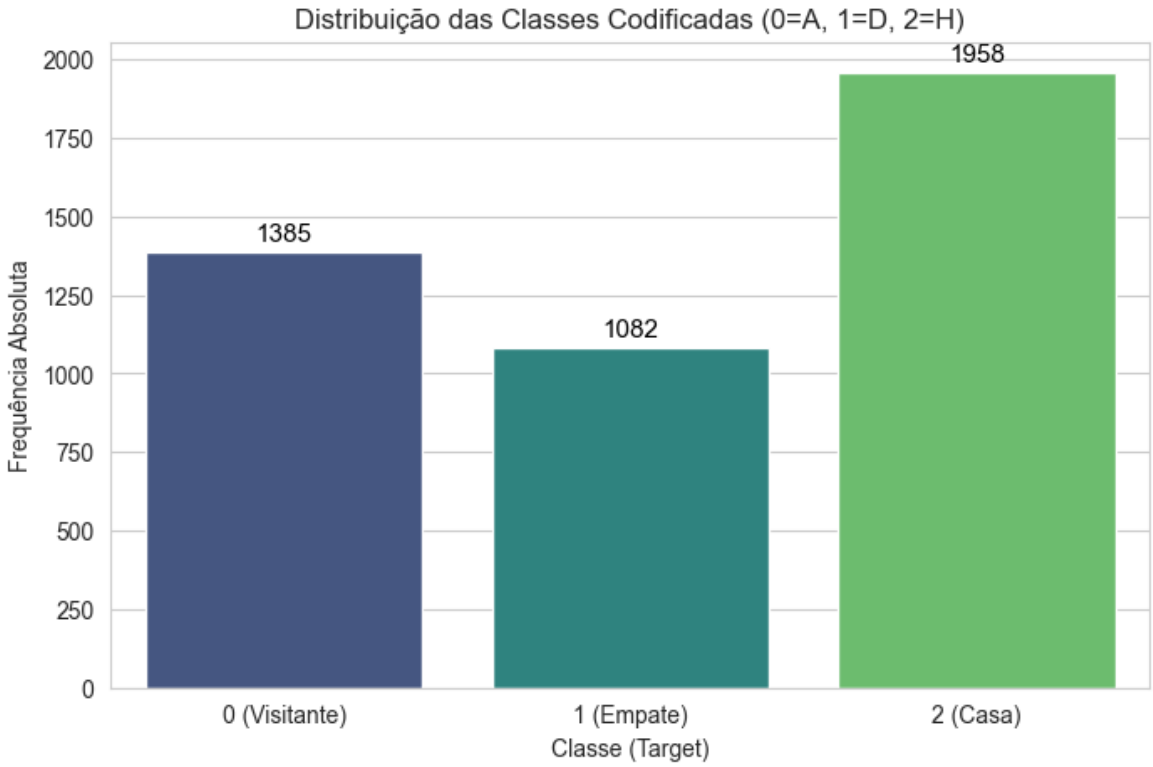

Figura 9 Distribuição das classes após codificações (dataset de treino)

- **Abordagem aos Identificadores de Equipas: Identidade Estatística**

O tratamento dos nomes das equipas (Casa e Visitante) levantou um problema interessante de generalização. A abordagem clássica seria criar uma coluna para cada equipa (*One-Hot Encoding*), mas descartei essa ideia por dois motivos práticos. Primeiro, a rotação constante de equipas na Liga ao longo de 20 anos (promoções e despromoções) criaria dezenas de colunas quase vazias, diluindo a informação útil. Além disso, havia o problema das equipas novas. Se o modelo decorasse que 'o Benfica ganha', ficaria sem saber o que fazer quando aparecesse uma equipa que nunca viu antes.

Optou-se por remover os nomes das equipas da matriz de treino, substituindo a "identidade nominal" por uma "identidade estatística". Basicamente, cada equipa passa a ser representada apenas pelos seus números (o histórico de *xG*, os pontos da época anterior, etc.). Desta forma, o modelo não aprende que "o Sporting ganha frequentemente". Em vez disso, aprende que "equipas com *xG* superior a 2.0 e 70 pontos na época passada ganham frequentemente". Esta abstração é crucial porque permite que o modelo avalie qualquer equipa, mesmo uma que acabou de subir de divisão, baseando-se na sua competência real e não no peso histórico do seu nome.

5.3.2 Variáveis de Desempenho Histórico e Forma Recente

A construção das variáveis preditivas baseou-se numa ideia simples: decompor o desempenho em duas dimensões temporais distintas. Por um lado, temos a capacidade estrutural consolidada (os dados históricos), e por outro, o momento de forma atual.

A. Variáveis Históricas e Integridade Temporal (*Lagging*)

Para modelar a força relativa das equipas sem incorrer em *data leakage*, implementei uma estratégia de *lagging* sazonal. Na prática, isto significa que as variáveis com o prefixo *Home_hist_* e *Away_hist_* olham exclusivamente para o que aconteceu na época anterior.

Este conjunto de dados é bastante abrangente. Começa pelo volume de jogos e distribuição de resultados, mas aprofunda-se na vertente ofensiva através dos Golos e do *xG*, bem como na eficácia de remate. Na defesa, o foco incide sobre os golos sofridos, o *xG* concedido (*xGA*) e a percentagem de *Clean Sheets*. Por fim, para caracterizar o perfil tático distinguindo quem domina a posse de quem joga em contra-ataque incluí métricas de estilo de jogo como passes progressivos e condução de bola.

B. Variáveis de Forma Recente (*Rolling Windows*)

Para conseguir captar a volatilidade do desempenho atual, foram implementadas janelas deslizantes (*rolling windows*) sobre os últimos 5 jogos da competição. Foi escolhida especificamente esta janela de 5 jogos por considerar ser o equilíbrio ideal: é suficientemente recente para ser relevante, mas tem amostra suficiente para ter significado estatístico. As variáveis de forma calculam a soma acumulada neste período para vários indicadores, nomeadamente os Pontos (o principal indicador de *momentum*) e os Golos (marcados e sofridos), que medem a eficácia ofensiva e a permeabilidade defensiva.

Quero destacar a decisão de incluir explicitamente a contagem de empates (Empates5) nesta janela. Esta variável não estava no plano original, mas nasceu de uma necessidade prática: durante os testes, percebi que o modelo tinha muita dificuldade em prever empates (tinha um *Recall* baixo na classe 'D'). A minha hipótese é que certas equipas adotam estilos táticos conservadores de forma sistémica ou atravessam fases de "bloqueio". Ao isolar a frequência recente de empates, ajudo o modelo a identificar estes padrões de jogos fechados que escapam quando olhamos apenas para golos ou vitórias.

A mecânica de cálculo destas janelas segue uma lógica *FIFO* (*First-In, First-Out*), ou seja, quando entra um jogo novo, sai o mais antigo, conforme detalhado no exemplo prático da Tabela 7.

Tabela 7 Lógica de Cálculo da Janela Deslizante (FIFO - 5 Jogos)

Jogo	Resultado	Pontos	Janela de 5 jogos	Soma (Pts5)	Cálculo
1	Vitória	3	[3]	3	-
2	Empate	1	[3,1]	4	-
3	Vitória	3	[3,1,3]	7	-
4	Derrota	0	[3,1,3,0]	7	-
5	Vitória	3	[3,1,3,0,3]	10	Soma inicial
6	Empate	1	[1,3,0,3,1]	8	10-3 (Jogo 1) + 1 (Jogo 6)

C. Métricas Avançadas (*Advanced Analytics*)

A decisão de incluir métricas avançadas do FBRef teve um propósito claro: tentar anular a aleatoriedade das estatísticas tradicionais. Todos sabemos que o número de golos marcados pode ser enganador, basta um golo sortudo ou um erro de arbitragem para distorcer a realidade, mas as métricas de "processo" isolam a qualidade real das ações, oferecendo uma base muito mais estável para fazer previsões.

No que toca aos Expected Goals (xG), integrei as variáveis de histórico de *xG* e *npxG* (sem penáltis) para quantificar a qualidade das oportunidades. A lógica é que

o xG é um indicador de desempenho futuro muito mais fiável do que os golos reais. Para complementar, adicionei as SCA/GCA (Ações de Criação de Remate/Golo). Estas métricas medem o volume ofensivo real (passes chave, dribles, faltas sofridas) e são fundamentais porque me permitem distinguir as equipas que criam perigo de forma sistémica daquelas que apenas dependem de eficácia pontual.

Relativamente às Métricas de Progressão e Domínio Territorial, aconteceu algo interessante durante a modelação: a análise de importância do *XGBoost* colocou consistentemente estes dados no topo da hierarquia de decisão. Refiro-me especificamente aos Passes Progressivos e às Conduções Progressivas. O modelo interpretou estes dados como os melhores indicadores de domínio territorial (*Field Tilt*). Basicamente, aprendeu que a capacidade de empurrar o bloco adversário para a sua zona defensiva é um sinal mais forte de vitória do que simplesmente ter uma posse de bola elevada, mas inofensiva.

D. Variáveis de Consenso de Mercado (*Odds*)

Foram integrados também os dados das casas de apostas no dataset, partindo do princípio da Hipótese do Mercado Eficiente. A lógica é que a *Closing Odd* (a probabilidade no momento em que o jogo começa) acaba por incorporar toda a informação pública disponível, incluindo fatores que as minhas estatísticas puras não captam, como lesões de última hora, condições meteorológicas ou a motivação interna das equipas no balneário.

Para capturar este "sinal externo", foram criadas duas variáveis principais. Primeiro, o Consenso (Odd_Media), que é a média aritmética das *odds* de cerca de 10 casas de apostas. Ao fazer esta agregação, consigo limpar as variações específicas de cada operador e obter uma estimativa mais robusta da probabilidade real. Segundo, utilizei as probabilidades do mercado de golos (Avg>2.5) como um indicador da natureza tática esperada, ou seja, para perceber se o mercado espera um jogo aberto ou fechado.

Contudo, é crucial esclarecer que a inclusão das *odds* não serve para "copiar" o mercado, mas sim para estabelecer uma linha de base. O grande objetivo do modelo é identificar divergências, ou seja, encontrar aqueles jogos onde as minhas métricas estatísticas (*xG*, Forma) contradizem a expectativa das casas de apostas. Para validar isto, realizei um estudo de ablação durante a fase experimental onde removi totalmente as *odds*. O resultado foi muito positivo: a precisão manteve-se estável na casa dos 57%, o que prova que as métricas de *Advanced Analytics* que recolhi conseguem, por si sós, capturar a maior parte da informação necessária, não ficando dependentes do mercado.

A Figura 10 ilustra perfeitamente esta dinâmica, mostrando a correlação inversa entre as Odds da Casa e o xG histórico. O que interessa aqui não é a linha diagonal óbvia, mas sim a dispersão fora dela: são esses pontos que representam as oportunidades de valor onde o modelo deteta algo que o mercado está a ignorar.

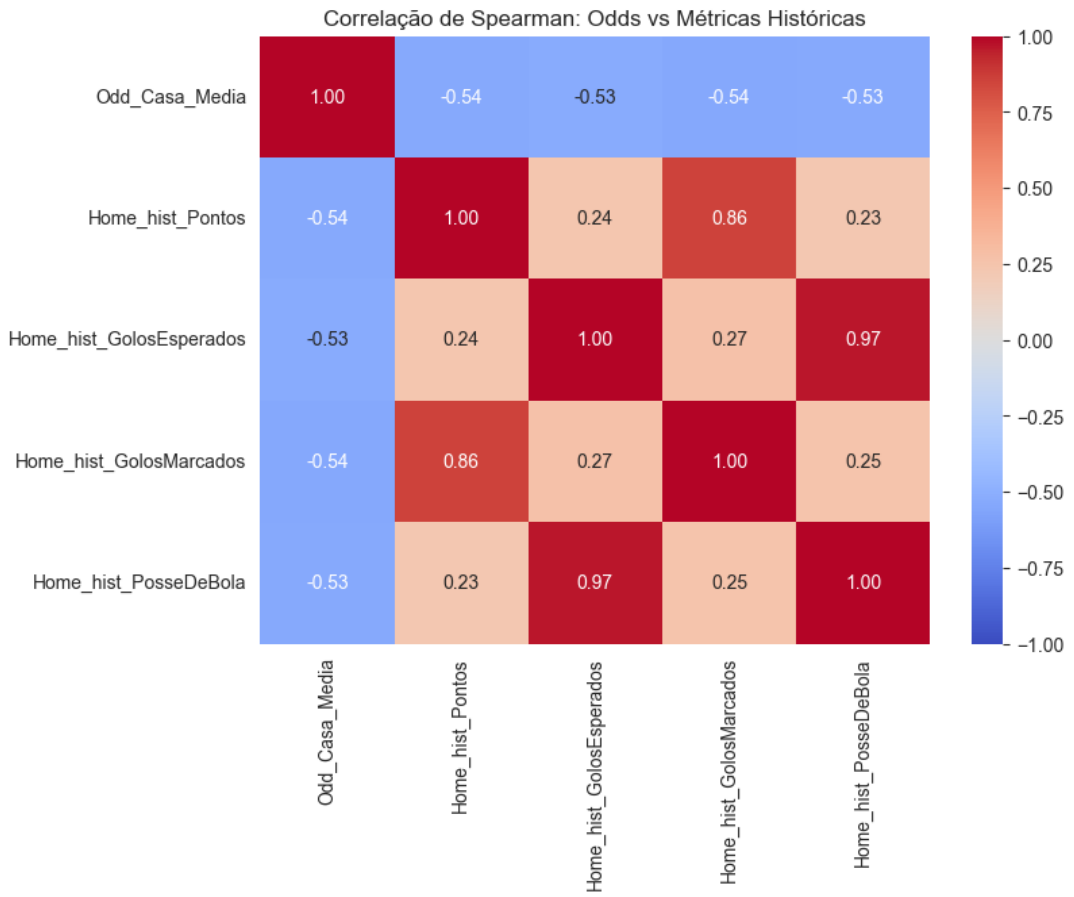

Figura 10 Correlação entre Odds Médias e Métricas avançadas

5.4 Metodologia Experimental

A estratégia desenhada para esta fase experimental teve um objetivo muito prático: replicar exatamente as condições que um modelo enfrenta no mundo real, semana após semana. Ao contrário de outros problemas de classificação onde os dados são estáticos, o futebol é um domínio em constante mutação, onde as táticas evoluem, os jogadores mudam de clube e os treinadores são despedidos.

Consequentemente, a metodologia priorizou a mitigação do *Look-ahead Bias* (uso de informação futura para prever o passado) e a prevenção de *Data Leakage*. A validação dos modelos não se baseia na aleatoriedade, mas sim na estrita cronologia dos eventos.

5.4.1 Estratégia de Partição: *Strict Temporal Holdout*

Para avaliar bem os modelos, é crucial que a separação dos dados respeite a ordem temporal. Se usássemos um método aleatório de validação cruzada, que é comum noutros contextos, estaríamos a cometer um erro grave: o modelo poderia, inadvertidamente, estar a "espreitar" resultados futuros (por exemplo, usar padrões da jornada 30) para tentar prever jogos do passado (como a jornada 5). Para evitar por completo este problema, a divisão foi feita de forma estritamente cronológica, usando a época como linha de corte.

- **Definição dos Conjuntos de Dados**

O histórico completo, desde 2010/11 até 2023/24, foi dividido em dois blocos consecutivos:

- **Para treinar os modelos,** foi usado tudo desde 2010/11 até 2022/23 (13 épocas, cerca de 4100 jogos). Esta base de dados alargada é fundamental por dois motivos: primeiro, dá dados suficientes para os algoritmos mais complexos (como o XGBoost) identificarem relações não óbvias ao longo dos anos, segundo, permite-nos equilibrar artificialmente as classes (com a técnica SMOTE) sem o risco de criar padrões irreais, coisa que poderia acontecer se a amostra inicial fosse muito pequena.

- **Para o teste final**, reservou-se exclusivamente a época 2023/24. Este conjunto funciona como uma prova de fogo "fora do tempo" (*Out-of-Time*), onde avaliamos se o modelo, treinado no passado, consegue de facto generalizar e fazer boas previsões na realidade mais recente do campeonato português.

A distribuição exata destes conjuntos está sumarizada na Tabela 8.

Tabela 8 Distribuição Temporal e Quantitativa dos Conjuntos de Dados

Conjunto	Épocas	Descrição	Função Principal
Treino	2010/2011 - 2022/2023	Histórico consolidado de 13 temporadas. Inclui variáveis de forma, histórico de confrontos diretos e métricas avançadas (xG)	Aprendizagem dos padrões e treino dos modelos (com e sem balanceamento)
Teste	2023/2024	Dados da temporada subsequente completa	Avaliação final de performance em dados “não vistos”

- **Validação de Hiperparâmetros (*Time Series Split*)**

A otimização de hiperparâmetros (ex: *max_depth, learning_rate* no XGBoost) exigiu uma estratégia de validação interna que respeitasse a ordem temporal. Em substituição do conjunto de validação fixo, implementou-se um **Time Series Split** com janelas expansivas (*Expanding Window Cross-Validation*).

O processo iterativo define-se da seguinte forma:

- **Iteração 1:** Treino $[t0, tk] \rightarrow$ Validação $[tk + 1]$
- **Iteração 2:** Treino $[t0, tk + 1] \rightarrow$ Validação $[tk + 2]$
- **Iteração n:** Treino $[t0, tn] \rightarrow$ Validação $[tn + 1]$

Esta abordagem assegura que o modelo é sempre validado em dados futuros relativamente ao treino, fornecendo uma estimativa robusta do erro de

generalização e prevenindo o *overfitting* a uma época específica. A implementação no código garante que não existe contaminação entre as janelas de desenvolvimento e o conjunto de teste final (2023/24).

5.5 Discussão dos Resultados e Seleção do Modelo

Nesta secção, analisamos de perto o desempenho dos vários modelos construídos. O grande desafio aqui, dada a imprevisibilidade inerente do futebol português, é separar o que é um padrão estatístico genuíno da simples aleatoriedade. O nosso objetivo final é claro: perceber se as abordagens mais complexas que desenvolvemos trouxeram uma vantagem real, superando de facto os métodos tradicionais mais simples que servem como ponto de partida.

5.5.1 Comparação de Arquiteturas: Linear vs. Ensemble

A avaliação começou por uma comparação direta entre os modelos clássicos e lineares e os métodos de *ensemble* mais modernos. A pergunta de fundo era: será que a complexidade adicional dos modelos baseados em árvores, capazes de capturar relações não-lineares, se traduz num salto de performance real?

Desde o início, existiu um cuidado: a Exatidão global é uma métrica traiçoeira. No nosso contexto, onde a vitória da equipa da casa é frequente, um modelo ingénuo que apostasse sempre nesse resultado teria uma exatidão artificialmente alta sem fazer nenhuma previsão inteligente. Por isso, análise crítica centrou-se verdadeiramente no *F1-Score* e no *Recall*, métricas que nos obrigam a olhar para o desempenho em cada um dos três resultados possíveis. O objetivo final era encontrar um modelo que fizesse um bom equilíbrio (*trade-off*) entre ser preciso (*Precision*) e conseguir apanhar a maioria dos casos de cada resultado (*Recall*), e não apenas um que tivesse a taxa de acerto geral mais alta.

5.5.1.1 Desempenho dos Modelos de Referência (*Baselines*)

A fase inicial de experimentação visou estabelecer linhas de base para o desempenho preditivo. Contrariamente à expectativa teórica, o modelo linear (Regressão Logística) superou inicialmente os modelos não-paramétricos (Árvore de Decisão e XGBoost sem otimização), atingindo uma Exatidão de 57%.

A Tabela 9 ilustra o desempenho comparativo destes modelos iniciais, evidenciando a robustez da abordagem linear face a abordagens não paramétricas sem otimização.

Tabela 9 Desempenho dos Modelos de Referência (Sem Balanceamento)

Modelo	Accuracy Global	Precision (Macro)	Recall (Macro)	F1-Score (Macro)	Recall (Empates)
Regressão Logística	**0.57**	0.48	0.42	0.44	~0.00
Árvore de	0.53	0.45	0.43	0.44	0.18

Decisão					
XGBoost (Inicial)	0.55	0.46	0.41	0.43	~0.02

Com base na avaliação inicial dos modelos, a estratégia adotada centrou-se na comparação entre algoritmos lineares clássicos e métodos de *ensemble* mais complexos. O objetivo era isolar o eventual ganho de performance resultante da capacidade de capturar relações não-lineares nos dados. Contrariando a expectativa teórica, o modelo linear de Regressão Logística superou inicialmente as abordagens não paramétricas, como a Árvore de Decisão e o *XGBoost* não otimizado, atingindo uma exatidão de 57%. Esta superioridade sugere que, numa primeira aproximação, a relação entre variáveis-chave (como a diferença de qualidade entre equipas) e a probabilidade de resultado apresenta uma componente linear dominante.

Contudo, a análise não pode depender só da exatidão dos números. A vantagem da Árvore de Decisão é permitir-nos entender o raciocínio por trás de cada previsão. A Figura 11 mostra a árvore gerada (com profundidade 4), onde conseguimos seguir o rasto das decisões tomadas pelo algoritmo.

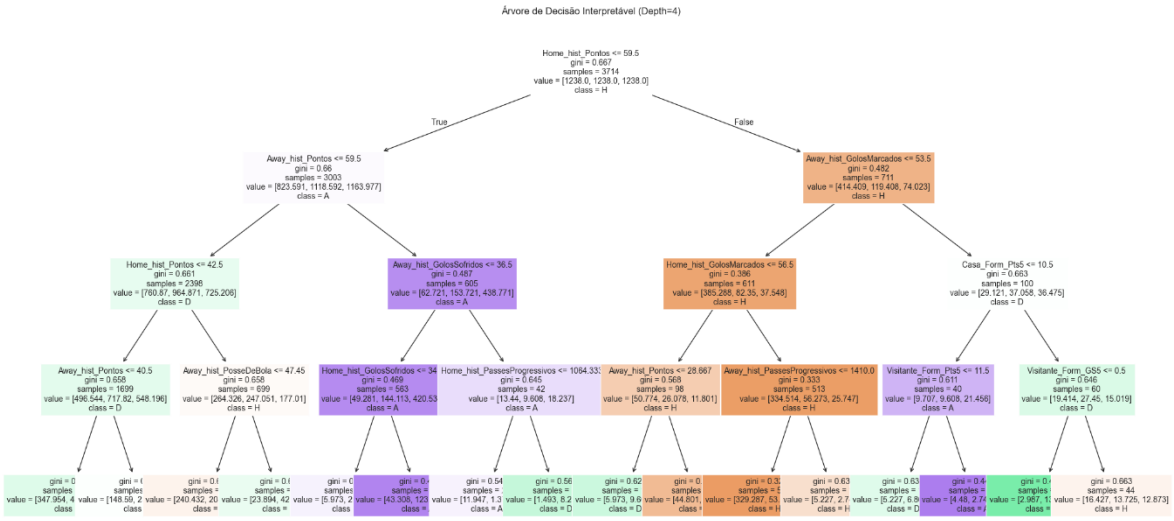

Figura 11 Árvore de Decisão e regras de classificação extraídas

Ao observar a estrutura, conseguimos extrair regras muito claras que, no fundo, validam o senso comum de quem vê futebol:

A Regra de Favoritismo da Casa (Caminho à Direita) onde, o modelo percebeu que se a equipa da casa tem um histórico forte (mais de 59.5 pontos) e o visitante tem um ataque fraco (poucos golos marcados), a probabilidade de ser uma Vitória da Casa é muito elevada.

A Regra de Força do Visitante (Caminho à Esquerda) que, por outro lado, se a equipa da casa for historicamente mais fraca e o visitante tiver uma pontuação alta na época anterior, o modelo inverte a lógica e prevê a Vitória do Visitante.

Apesar desta clareza conceptual, deparei-me com um problema crítico nesta fase: o modelo é praticamente "cego" aos Empates (Recall nula ou muito baixa). Tanto esta Árvore como a Regressão Logística e o *XGBoost* inicial optaram pelo caminho mais fácil: ignorar a classe minoritária (o empate) para maximizar a taxa de acerto global. Em termos práticos, isto é uma falha grave, pois torna o modelo ineficaz para detetar jogos equilibrados onde o risco é maior.

5.5.1.2 Estabilização do XGBoost e Regularização

A adoção do XGBoost visou capturar relações não-lineares complexas. No entanto, as primeiras iterações revelaram um severo *overfitting*: o modelo atingiu 95% de Exatidão no treino, caindo para 52% no teste. O algoritmo memorizou o ruído dos dados históricos em vez de aprender padrões táticos generalizáveis.

Para mitigar este comportamento, implementou-se uma estratégia de regularização rigorosa através de *GridSearchCV*. Foi feita uma redução drástica à complexidade do modelo, limitando a profundidade máxima das árvores a 3, fez-se um abrandamento da aprendizagem, baixando a taxa de aprendizagem (*learning rate*) para 0.01, o que força o modelo a "pensar" mais devagar e a construir soluções mais robustas e por último introduziu-se um elemento de aleatoriedade (*subsample*) para que cada árvore fosse treinada com uma ligeiramente diferente amostra dos dados, aumentando a diversidade do *ensemble*.

Estas alterações tiveram o efeito desejado: a Exatidão estabilizou nos **57%**, e a diferença abismal entre o desempenho no treino e no teste desapareceu.

5.5.1.3 Estratégias de Balanceamento: SMOTE vs. Pesos de Classe

Para corrigir a incapacidade do modelo em prever empates, testaram-se duas abordagens distintas: geração de dados sintéticos (SMOTE) e aprendizagem sensível ao custo (*Class Weights*).

Esta fase experimental gerou os resultados mais interessantes e divergentes do projeto, ilustrados na Figura 11

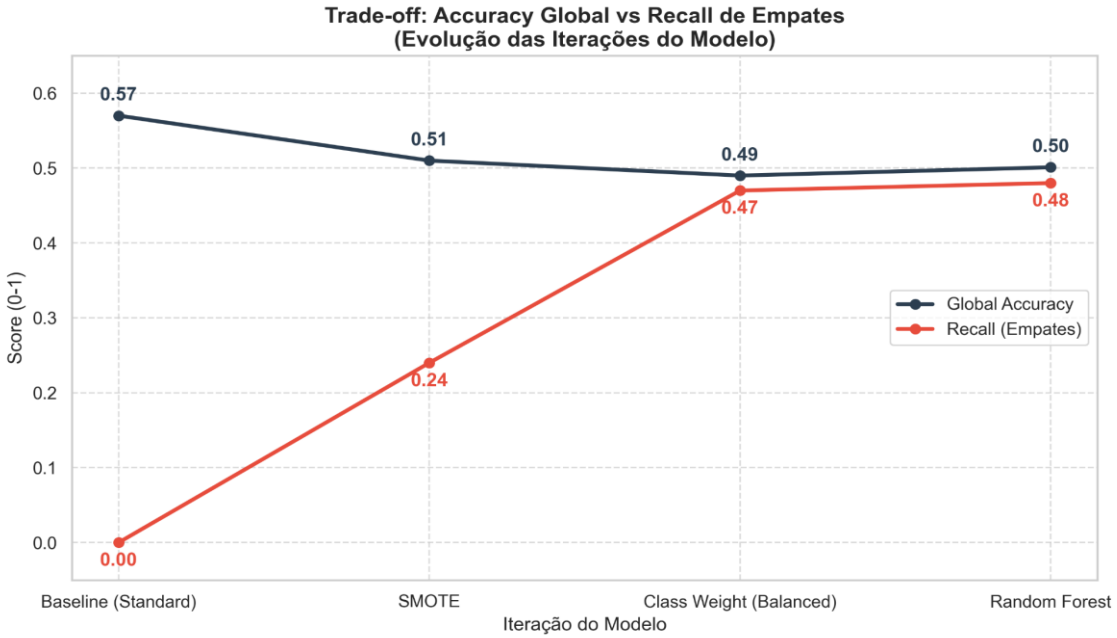

Figura 12 Gráfico de Linhas comparando a evolução da Recall (Empates) vs. Exatidão Global ao longo das iterações do modelo

- **A Abordagem Sintética: SMOTE**

Ao criar exemplos artificiais de empates no conjunto de treino, conseguimos aumentar a sensibilidade do modelo. A Recall para empates subiu para 24%, um progresso inegável. No entanto, esse ganho teve um preço: a Exatidão global recuou para 50.8%. Pior ainda, a precisão das previsões de empate manteve-se baixa (32%), o que na prática significava que, quando o modelo previa um empate, errava com frequência. Em retrospetiva, injetar dados sintéticos num domínio tão ruidoso como o futebol pode ter criado padrões irreais que confundiram o modelo.

- **A Abordagem de Penalização: *Class Weights***

Em vez de fabricar dados, esta técnica atua no algoritmo de aprendizagem, atribuindo um custo maior sempre que o modelo se engana num empate. Os resultados foram marcadamente diferentes. O modelo sacrificou uma margem da sua acurácia global (que ficou em **49.3%**), mas em troca alcançou uma Recall para empates de 47%, ou seja, passou a identificar quase metade de todos os empates reais que ocorreram.

5.5.1.4 Seleção Final: Random Forest com Pesos Balanceados

Na reta final da seleção, colocámos o nosso XGBoost otimizado frente a frente com um modelo alternativo: a Random Forest Classifier, configurado com 100 árvores e os mesmos pesos balanceados para as classes. O objetivo era encontrar o ponto ideal entre robustez estatística e a sensibilidade aos empates que tanto procurávamos.

Tabela 10 Comparação de Performance XGBoost (SMOTE/Weights) vs Random Forest

Modelo/Estratégia	***Accuracy* Global**	***Precision* (Empate)**	***Recall* (Empate)**	**F1-*Score* (Empate)**	***Recall* (Vitória Casa)**	***Recall* (Vitória Fora)**
XGBoost + SMOTE	0.508	0.32	0.24	0.27	0.66	0.53
XGBoost + Weights	0.493	0.32	0.47	0.38	0.51	0.49
Random Forest + Weights	0.501	0.33	0.48	0.39	0.53	0.48

Os resultados dessa comparação decisiva estão detalhados na Tabela 10. A Random Forest com pesos balanceados mostrou-se ligeiramente, mas consistentemente, superior nas métricas que mais nos importavam. Conseguiu um **Recall para empates de 48%** e um **F1-Score de 0.39**, superando o *XGBoost* na tarefa mais difícil, e manteve a Acurácia global acima da barreira simbólica dos 50%.

5.5.2 Análise da Importância das Variáveis (*Feature Importance*)

A validação da estratégia de engenharia de atributos foi realizada através da análise de importância das variáveis do modelo final (*Random Forest*). Utilizou-se a métrica de Redução Média de Impureza de Gini (*Mean Decrease in Impurity*) para quantificar o contributo relativo de cada atributo na redução da entropia dos nós da árvore.

A hierarquia de importância resultante permite validar as hipóteses iniciais sobre a dinâmica do jogo e identificar os preditores mais influentes.

5.5.2.1 Preponderância do Histórico Estrutural sobre a Forma Recente

A análise quantitativa revelou que as variáveis de histórico Geral (acumulado da época anterior) possuem um peso preditivo significativamente superior às variáveis de Forma Recente (janela de 5 jogos).

Atributos estruturais como *Home_hist_Pontos* e *Home_hist_GolosMarcados* ocupam consistentemente o topo do *ranking*.

- **Interpretação:** A qualidade estrutural de uma equipa, consolidada ao longo de uma época completa (~34 jogos), constitui um estimador de desempenho mais robusto do que a forma de curto prazo. As janelas de 5 jogos apresentam elevada variância estatística, podendo ser influenciadas por calendários favoráveis ou fatores aleatórios momentâneos.
- **Exceção da "Tendência ao Empate":** Identificou-se, contudo, uma relevância específica na variável *Visitante_Form_Empates5* nos modelos com pesos balanceados. Isto sugere que a propensão para empatar é um

traço comportamental persistente em certas equipas (perfil defensivo), que se manifesta em *clusters* temporais, sendo capturada eficazmente pela janela deslizante.

5.5.2.2 Validação de Métricas Avançadas (xG e Progressão)

A análise da importância das variáveis trouxe uma confirmação clara: as métricas avançadas que introduzimos a partir dos dados do FBRef trouxeram, de facto, um poder discriminativo que as estatísticas tradicionais sozinhas não capturavam. Dois indicadores destacaram-se de forma consistente no topo da hierarquia de importância, como se pode ver na Figura 12.

Em primeiro lugar, os Passes Progressivos da equipa da casa (*Home_hist_PassesProgressivos*) afirmaram-se de forma consistente entre as 10 variáveis mais importantes. Esta validação é significativa: na prática, a métrica provou ser um indicador muito mais útil para medir o domínio territorial e a construção de jogo efetiva do que a simples posse de bola, que pode ser estéril e sem avanço. O modelo interpretou a capacidade de uma equipa avançar o jogo com passes verticais como um sinal forte de perigo ofensivo iminente.

Em segundo lugar, a grande relevância atribuída ao *Expected Goals* da equipa da casa (*Home_hist_xG*) foi decisiva. O que isto nos diz é que o modelo aprendeu a distinguir entre um desempenho sustentável e a simples sorte momentânea na finalização. Ao dar mais peso ao *xG* do que aos golos marcados em certas decisões, o algoritmo demonstrou entender o conceito de regressão à média: desvalorizou implicitamente equipas que tiveram uma fase de eficácia excecional (e provavelmente insustentável) à frente da baliza, e soube valorizar equipas que criavam boas oportunidades de golo, mesmo que estivessem a passar por uma fase de finalização pouco afortunada.

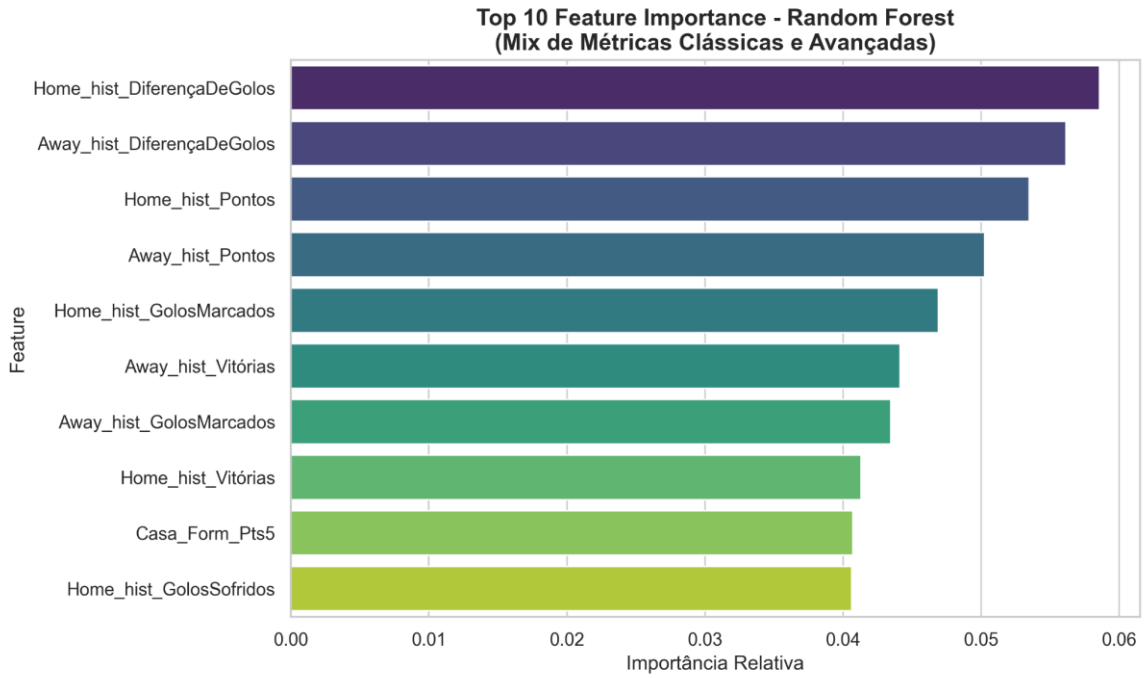

Figura 13 Top 10 *Feature Importance* do Modelo *Random Forest*

5.5.2.3 Redundância Informativa das *Odds* de Mercado

Durante o processo de seleção de variáveis, identificou-se uma redundância significativa entre as *odds* das casas de apostas e as métricas estatísticas recolhidas. Testes de ablação demonstraram que a remoção das variáveis de mercado (que contêm implicitamente a probabilidade de consenso) não resultou na degradação da Exatidão do modelo, que se manteve estável nos 57%.

Este resultado permite concluir que o vetor de características estatísticas construído (*xG*, Histórico, Métricas de Progressão) possui suficiência informativa. O modelo conseguiu reconstruir a lógica probabilística do jogo de forma autónoma, validando a integridade dos dados obtidos via *web scraping* e a eficácia das métricas de *Advanced Analytics* em capturar o sinal preditivo sem dependência de *inputs* de terceiros.

5.5.3 Seleção do Modelo Final

A seleção do modelo final foi guiada por um princípio claro: a utilidade prática sobrepôs-se à maximização cega de uma única métrica. Se o único objetivo fosse a Exatidão (*Accuracy*) global, teríamos ficado pela Regressão Logística ou pelo *XGBoost* inicial, ambos com 57%. No entanto, esses modelos falhavam redondamente no ponto central do projeto: eram praticamente cegos à classe "Empate", que representa cerca de 30% dos resultados reais. Um modelo que não vê empates é, para os nossos objetivos, um modelo inútil.

A escolha pelo *Random Forest Classifier* com pesos balanceados baseou-se na convergência de três fatores decisivos que, em conjunto, garantem um modelo prático e robusto.

Em primeiro lugar, este modelo atingiu o equilíbrio mais inteligente entre métricas, sacrificando uma ligeira margem de exatidão global (50.1%) para obter um recall de 48% nos empates, transformando-se assim numa ferramenta capaz de gerar alertas valiosos para os resultados mais difíceis e com maior *odd*.

Em segundo, demonstrou uma estabilidade natural superior à do *XGBoost*, pois a sua arquitetura de *bagging* controlou de forma intrínseca a variância, sem exigir a regularização agressiva que foi necessária no *boosting*, dando-nos mais confiança na sua generalização.

Por fim, a análise da Tabela 11 (Matriz de Confusão) revelou um perfil de erros equilibrado e interpretável: os 190 falsos positivos na classe de empate distribuem-se de forma quase simétrica entre vitórias da casa e do visitante, sugerindo que muitos correspondem a jogos efetivamente equilibrados, decididos por detalhes. Esta combinação de sensibilidade tática, robustez estatística e transparência nos erros validou o Random Forest como a escolha final mais adequada.

Tabela 11 Matriz de Confusão Simplificada do Modelo Final (*Random Forest*)

	Previsto: Visitante (A)	**Previsto: Empate (D)**	**Previsto: Casa (H)**
Real: Visitante (A)	130 (48%)	85	55
Real: Empate (D)	60	111	61
Real: Casa (H)	75	105	**203** (53%)

A análise dos erros na classe "Empate" (Falsos Positivos: 190 jogos previstos como empate que tiveram vencedor) indica uma simetria na distribuição (85 vitórias 'A' vs 105 vitórias 'H'). Muitos destes falsos positivos correspondem a jogos decididos pela margem mínima, sugerindo que a leitura tática do modelo (previsão de jogo equilibrado) estava fundamentada, apesar de o desfecho estocástico ter pendido para um dos lados.

5.5.4 Conclusão da Seleção

A escolha do *Random Forest* (Balanced) fundamenta-se na sua capacidade de modelar a incerteza estrutural da Primeira Liga portuguesa. Ao contrário das abordagens lineares que maximizam o acerto prevendo os favoritos, este modelo incorpora métricas de *Advanced Analytics* (xG, Passes Progressivos) e penalização de erros para capturar a classe minoritária. O resultado é uma ferramenta analítica que não se limita a memorizar a tabela classificativa, mas que identifica eficazmente os cenários de equilíbrio tático.

6. Conclusões

Este projeto representou para mim a oportunidade de unir duas das minhas grandes paixões: o futebol e a ciência de dados. O percurso desde a recolha dos primeiros dados até ao modelo final foi, acima de tudo, um processo de aprendizagem intensivo que me permitiu confirmar uma ideia que já suspeitava: prever resultados desportivos é muito mais do que aplicar algoritmos complexos. É, sobretudo, um exercício de compreensão do problema, de limpeza rigorosa de dados e de escolhas estratégicas que equilibram a precisão técnica com a utilidade prática.

O sistema desenvolvido, baseado num modelo de Random Forest com pesos balanceados para as classes, conseguiu atingir um nível realista entre a exatidão global e a capacidade de detetar resultados difíceis, como os empates. Este foi, sem dúvida, o maior desafio técnico do projeto. Conseguimos fazê-lo passar de uma *recall* praticamente nula para valores próximos dos 48%, um avanço significativo que transformou o modelo de uma ferramenta teórica num sistema com aplicabilidade concreta. A lição mais valiosa foi perceber que, por vezes, é preciso sacrificar alguns pontos percentuais de acerto geral para ganhar inteligência tática e capacidade de identificar as situações mais valiosas e menos óbvias.

6.1 Síntese do Trabalho Desenvolvido e Resultados Alcançados

O trabalho seguiu uma metodologia prática e estruturada, desde a conceção até à implementação. Começou pela construção manual de um *dataset* robusto, que juntou dados de resultados e *odds* com métricas avançadas de desempenho, como os *Expected Goals* e os passes progressivos. Esta fase, embora demorada, foi absolutamente crítica. Confirmou-se que a qualidade dos dados de entrada é o fator que mais impacta o sucesso final, mais até do que a escolha do algoritmo em si.

Na fase de modelação, a comparação entre abordagens simples e complexas trouxe uma conclusão clara. Enquanto modelos lineares como a Regressão Logística serviam como uma *baseline* sólida, foram os métodos de *ensemble*, em particular o Random Forest, que revelaram a capacidade de capturar interações não lineares e padrões táticos mais profundos. O modelo final, otimizado com pesos para as classes, não se limitou a "adivinhar" o favorito. Aprendeu a reconhecer sinais de equilíbrio e a atribuir probabilidades mais realistas aos três desfechos possíveis, atingindo um F1-Score global de 0.51 numa época de teste recente, um resultado muito positivo num domínio tão imprevisível como o futebol da Primeira Liga.

6.3 Propostas de Trabalho Futuro

Olhando para a frente, há algumas ideias que gostaria de testar numa próxima fase. Primeiro, melhorar os dados. Seria interessante incluir informações sobre lesões de jogadores importantes, o valor de mercado dos plantéis, ou até o tempo no dia do jogo. Tudo o que possa influenciar o jogo e que o modelo ainda não vê. Depois, experimentar outros tipos de modelos. Gostava de testar LSTM para ver se

conseguem captar melhor a "forma" de uma equipa ao longo do tempo, em vez de olhar apenas para os últimos 5 jogos.
Por fim, o passo mais gratificante: tornar isto útil. Transformar o projeto num site ou num *dashboard* simples onde se pudesse simular o campeonato ou ver previsões para a próxima jornada. Era a forma de dar vida prática a todo este trabalho.

Fontes

[1] «Brief Definitions of Key Terms in AI | Stanford HAI». Acedido: 6 de janeiro de 2026. [Online]. Disponível em: https://hai.stanford.edu/policy/brief-definitions-of-key-terms-in-ai

[2] S. J. Russell e P. Norvig, *Artificial intelligence: a modern approach*, Fourth edition, Global edition. em Prentice Hall series in artificial intelligence. Boston: Pearson, 2022.

[3] R.P.F, «Machine Learning Definitions from the Field's Experts», How to Learn Machine Learning. Acedido: 6 de janeiro de 2026. [Online]. Disponível em: https://howtolearnmachinelearning.com/articles/machine-learning-definitions-from-the-fields-experts/

[4] «Machine learning», *Wikipedia*. 1 de janeiro de 2026. Acedido: 6 de janeiro de 2026. [Online]. Disponível em: https://en.wikipedia.org/w/index.php?title=Machine_learning&oldid=1330613401

[5] R. Bunker, C. Yeung, e K. Fujii, «Machine Learning for Soccer Match Result Prediction», em *Artificial Intelligence, Optimization, and Data Sciences in Sports*, vol. 218, M. J. Blondin, I. Fister, e P. M. Pardalos, Eds., em Springer Optimization and Its Applications, vol. 218. , Cham: Springer Nature Switzerland, 2025, pp. 7–49. doi: 10.1007/978-3-031-76047-1_2.

[6] «(PDF) Predicting Football Match Outcomes with Machine Learning Approaches», *ResearchGate*, ago. 2025, doi: 10.13164/mendel.2023.2.229.

[7] I. M. Boucinha, «Um modelo de previsão de resultados de futebol utilizando Machine Learning», *A model to predict outcomes of soccer matches using machine learning*, 2023, Acedido: 21 de janeiro de 2026. [Online]. Disponível em: https://lume.ufrgs.br/handle/10183/261788

[8] «Predicting Portuguese Primeira Liga match outcomes with Machine Learning | by Paulo Matos | Medium». Acedido: 18 de novembro de 2025. [Online]. Disponível em: https://medium.com/@paulo.matos16/predicting-portuguese-primeira-liga-match-outcomes-with-machine-learning-1af84c06041a

[9] «sklearn.metrics», scikit-learn. Acedido: 21 de janeiro de 2026. [Online]. Disponível em: https://scikit-learn/stable/api/sklearn.metrics.html

[10] «Applying Machine Learning to Sports Betting», Quant Galore. Acedido: 21 de janeiro de 2026. [Online]. Disponível em: https://www.quantgalore.com/pages/applying-machine-learning-to-sports-betting

[11] «(PDF) Recall and Precision versus the Bookmaker», em *ResearchGate*, doi: 10.13140/RG.2.1.3754.1926.

[12] V. Jayaswal, «Performance Metrics: Confusion matrix, Precision, Recall, and F1 Score», Towards Data Science. Acedido: 21 de janeiro de 2026. [Online]. Disponível em: https://towardsdatascience.com/performance-metrics-confusion-matrix-precision-recall-and-f1-score-a8fe076a2262/

[13] «(PDF) Predicting Football Outcomes by Using Poisson Model: Applied to Spanish Primera División», *ResearchGate*, ago. 2025, doi: 10.38094/jastt204112.

[14] F. Sjöberg e S. A. Rashti, «Football Match Prediction Using Machine Learning».

[15] Y. Ren e T. Susnjak, «Predicting Football Match Outcomes with eXplainable Machine Learning and the Kelly Index», 28 de novembro de 2022, *arXiv*: arXiv:2211.15734. doi: 10.48550/arXiv.2211.15734.
[16] M. Lewandowski e M. Chlebus, «Predicting football outcomes from Spanish league using machine learning models».
[17] M. Fischer e A. Heuer, «Match predictions in soccer: Machine learning vs. Poisson approaches».
[18] «pawelp0499/football-prediction-model: Multinomial logistic regression model for predicting the outcomes of football matches». Acedido: 18 de novembro de 2025. [Online]. Disponível em: https://github.com/pawelp0499/football-prediction-model
[19] J. Stübinger, B. Mangold, J. Knoll, J. Stübinger, B. Mangold, e J. Knoll, «Machine Learning in Football Betting: Prediction of Match Results Based on Player Characteristics», *Appl. Sci.*, vol. 10, n.º 1, dez. 2019, doi: 10.3390/app10010046.
[20] D. Pettersson e R. Nyquist, «Recurrent Neural Network Applications».
[21] C. Araujo Rossmann Leite e C. Karlsson, *Predicting Premier League's match outcome via machine learning : New chess-inspired features can enhance predictions*. 2025. Acedido: 19 de novembro de 2025. [Online]. Disponível em: https://urn.kb.se/resolve?urn=urn:nbn:se:hh:diva-56235
[22] «Football Predictions AI – Apps no Google Play». Acedido: 19 de novembro de 2025. [Online]. Disponível em: https://play.google.com/store/apps/details?id=com.siron.footballpredictionsai&hl=pt_PT
[23] «What is XGBoost? | IBM». Acedido: 22 de janeiro de 2026. [Online]. Disponível em: https://www.ibm.com/think/topics/xgboost
[24] «Web Scraping with Selenium and Python: A Developer's Guide», DEV Community. Acedido: 24 de janeiro de 2026. [Online]. Disponível em: https://dev.to/alex_aslam/web-scraping-with-selenium-and-python-a-developers-guide-39hp
[25] «(PDF) Exploratory Data Analysis (EDA) on Undergraduate Data Science Students Through R Programming», ResearchGate. Acedido: 24 de janeiro de 2026. [Online]. Disponível em: https://www.researchgate.net/publication/395091688_Exploratory_Data_Analysis_EDA_on_Undergraduate_Data_Science_Students_Through_R_Programming